



Rapport de stage
Master 2 Informatique parcours MIND

Mesure de qualité de contextes causaux contrefactuels dans des Systèmes de Transition d'États Étiquetés avec prise en compte de normes

Encadrants :
Gauvain Bourgne
Isabelle Bloch
Marie-Jeanne Lesot
Yann Munro

Étudiante : Jeanne Bonnaventure
Numéro étudiant : 21111286

Année universitaire 2025–2026

Période de stage : Février - Août 2026

Remerciements

Je tiens tout d'abord à remercier l'ensemble des membres des équipes LFI et SMA, qui m'ont accueillie dans les meilleures conditions et m'ont permis de découvrir le monde de la recherche dans un cadre de partage et d'ouverture précieux.

Je souhaite très sincèrement remercier mes encadrants : Gauvain Bourgne, Isabelle Bloch, Marie-Jeanne Lesot et Yann Munro pour le suivi rigoureux et l'écoute qu'ils m'ont apportés tout au long de ce stage, pour la richesse de nos échanges, ainsi que pour leur travail de relecture de ce rapport.

Merci enfin à l'ensemble des doctorants et post-doctorants pour leurs conseils avisés et l'esprit d'équipe qu'ils font régner au sein des bureaux.

Table des matières

1 Introduction **1**

2 État de l'art **3**
2.1 Causalité effective . . . 3
2.2 Raisonnement sur l'action et le changement . . . 4
2.3 Explication contrefactuelle . . . 5
2.4 Responsabilité et sélection causale . . . 5

3 Définitions et notations **6**

4 Évaluation d'un contexte causal contrefactuel **8**
4.1 Fonction de coût proposée . . . 8
4.2 Distance à l'observation . . . 9
4.2.1 Distance de Levenshtein . . . 9
4.2.2 Intégration de la mutabilité . . . 10
4.3 Vraisemblance du contrefactuel . . . 11
4.3.1 Pondération des arcs . . . 11
4.3.2 Évaluation de la vraisemblance à partir d'une politique optimale . . . 12
4.3.3 Évaluation de la vraisemblance par agrégation de scores . . . 14
4.3.4 Sélection des événements à évaluer . . . 16
4.4 Acceptabilité des contrefactuels : filtres a posteriori . . . 17

5 Transition d'un framework RAC vers LTS : PDDL **17**
5.1 Rappel sur PDDL . . . 17
5.2 Construction d'un LTS à partir d'un problème PDDL . . . 18
5.3 Remarques et limites . . . 19
5.4 Exemple de problème PDDL . . . 19

6 Application : exemple du poison **20**
6.1 De PDDL vers un LTS . . . 20
6.2 Définition des contextes causaux . . . 22
6.3 Définition des politiques optimales . . . 23
6.4 Résultats . . . 23

7 Conclusion **27**

A Exemple de contexte causal non valide pour la fonction de coût **28**
A.1 Fonction *divergence* . . . 28
A.2 Fonction *correct* . . . 28

B Construction d'une politique optimale avec planification et l'utilisation de l'algorithme A* **28**

C Vérification des propriétés pour les opérateurs **29**
C.1 Opérateur géométrique . . . 29
C.2 Opérateur gamma . . . 30
C.3 Opérateur de seuil . . . 30
C.4 Synthèse des résultats . . . 31
C.5 Sensibilité de l'opérateur gamma au paramètre γ . . . 31

D Digression sur le concept de sélection causale dans le domaine des sciences cognitives **32**
D.1 Mutabilité et propensité des facteurs 32
D.2 Impact des normes sur le raisonnement contrefactuel 33
D.3 Influence du temps sur le raisonnement contrefactuel 33

E Démonstrations des propriétés du parseur **33**
E.1 Correction 34
E.2 Terminaison 35
E.3 Représentabilité 35

F PDDL **36**
F.1 Domaine Block World classique 36
F.2 Domaine et problème du Poison 37

1 Introduction

De nombreuses situations peuvent être décrites comme des séquences d'états et d'événements qui produisent un résultat particulier. Pour mieux comprendre les résultats de ces scénarios, il est assez naturel de s'interroger sur ce qui aurait pu se produire autrement. Et si une décision avait été différente ? Et si ce facteur n'avait pas été présent ? Ce type de réflexion, qui correspond à envisager des scénarios alternatifs à une réalité que l'on observe, est au centre du raisonnement contrefactuel (Menzies et Beebee 2025). Le raisonnement contrefactuel possède des applications concrètes dans de nombreux domaines. En droit, par exemple, un juge peut se demander si le dommage aurait eu lieu sans la faute de l'accusé. En médecine, on peut se demander si un patient aurait guéri sans un traitement. Cette réflexion permet de comprendre une situation, en identifiant les causes qui ont produit un effet.

S'intéresser formellement à ce raisonnement nous mène vers le domaine de la causalité effective, et plus particulièrement vers son approche contrefactuelle, qui définit une cause comme un fait qui produit une différence. Selon cette perspective introduite par Lewis "c est la cause de e" équivaut à "si c n'avait pas eu lieu, e n'aurait pas eu lieu non plus" (Lewis 1973), on cherche à définir des causes en observant les mondes possibles où la cause est absente.

Cette démarche consistant à explorer des mondes possibles pour comprendre un résultat observé se retrouve aussi dans le domaine de l'*eXplainable Artificial Intelligence* (XAI) avec les explications contrefactuelles. Pour expliquer la sortie produite par un système à partir d'une entrée donnée, on identifie la ou les entrées les plus proches qui conduisent à une sortie différente comme définie par Guidotti 2024. Cette notion de proximité est un sujet de recherche actif : de nombreux critères ont été proposés pour en préciser la définition et permettre la sélection de contrefactuels jugés "raisonnables" (Amgoud et Cooper 2026). On peut par exemple citer, la minimalité, qui impose que le changement sur l'entrée originale soit le plus faible possible, ou encore la diversité, qui promeut la génération de contrefactuels distincts pour la même entrée (Amgoud et Cooper 2026). Cette logique d'interrogation de mondes alternatifs rejoint celle mobilisée en causalité effective (Wachter, Mittelstadt et Russell 2017).

Comprendre une situation en explorant l'ensemble des mondes alternatifs concevables n'est pas possible en pratique, que ce soit sur le plan de la modélisation ou de la complexité. De plus ce n'est pas non plus pertinent sur le plan théorique, tous les mondes possibles ne présentant pas un intérêt à être comparé au monde observé. C'est dans cette idée qu'on introduit les normes. Une norme est un standard, qui permet de juger la conformité ou la déviance d'un objet relativement à nos attentes (D'Amico 2026). Une norme statistique reflète ce qui se produit habituellement tandis qu'une norme prescriptive reflète ce qui devrait se produire indépendamment de la fréquence effective. Par exemple si une plante meurt dans un jardin accessible par un jardinier et des passants, plusieurs mondes contrefactuels permettraient de la sauver. Toutefois, on aura tendance à privilégier celui où le jardinier, chargé d'entretenir les plantes, l'aura arrosé. Ce choix n'est pas arbitraire, il est guidé par nos attentes normatives. L'influence des normes sur cette sélection fait l'objet de travaux en sciences cognitives (Icard, Kominsky et Knobe 2017). Considérer les normes ne doit pas cependant amener à une confusion entre la question de la cause d'un effet et celle de la responsabilité d'une cause dans un effet. Dans l'exemple précédent les causes du décès de la plante sont le fait que le jardinier n'a pas arrosé la plante, mais aussi le fait qu'un passant n'a pas arrosé la plante. En causalité pure si l'un ou l'autre avait arrosé la plante, elle serait vivante. Si on s'interroge maintenant sur la responsabilité causale, on ciblera uniquement le jardinier, car son devoir était d'arroser la plante. L'articulation entre ces deux questions et le rôle que jouent les normes entre elles motivent une partie de ce travail.

La problématique de ce stage a été d'évaluer la qualité de scénarios contrefactuels par rapport à un scénario observé, selon différents critères tels que leur proximité à l'observation ou leur vraisemblance relativement à des normes. Le travail s'inscrit dans la continuité du cadre du Raisonnement sur l'Action et le Changement (*Reasoning about Action and Change*, RAC) introduit par Sarmiento et al. 2023 qui proposent un formalisme basé sur des systèmes de transitions d'états étiquetés (*Labelled Transition Systems*, LTS) prenant la forme de graphes orientés. Ce formalisme permet de modéliser les états du monde ainsi que ses transitions afin de raisonner sur des scénarios contrefac-

tuels. Son choix a notamment été motivé par son aspect général, car tout langage d'action en RAC peut être représenté sous forme de LTS (Sarmiento 2025). Dans notre cadre, les transitions sont déterministes : un état de départ donné et une politique déterministe, associant à chaque état un événement, déterminent entièrement une trajectoire (ou scénario) dans le LTS. On appelle contexte causal le couple formé par une telle politique et un état de départ.

L'article de Sarmiento et al. (2023) porte sur la formalisation de cas de surdétermination en causalité effective. Des cas de surdétermination sont des cas où plusieurs causes sont présentes et suffisantes pour produire un effet. L'article construit des politiques contrefactuelles simples pour caractériser ces cas. L'objectif du stage a été d'enrichir le travail sur la construction de politiques contrefactuelles en cherchant à évaluer leur qualité selon différents critères. Pour identifier ces critères, je me suis tournée vers le domaine de l'explicabilité, qui offre une littérature abondante sur la notion d'explication contrefactuelle et sur les propriétés qui en garantissent la pertinence. J'ai complété cette approche par des travaux issus des sciences cognitives, portant sur les concepts de sélection causale et d'attribution de responsabilité.

Ce rapport introduit une fonction de coût modulaire permettant d'évaluer la qualité de contextes causaux contrefactuels relativement à un contexte causal observé, ainsi qu'un parseur permettant une transition d'un problème exprimé *Planning Domain Description Language* (PDDL) vers le formalisme LTS. Une implémentation complète de l'évaluation et du cadre a aussi été développée en Python.

Ce rapport est organisé de la façon suivante : la section 2 présente un état de l'art permettant de faire le lien entre les différents domaines mobilisés. La section 3 reprend et adapte les définitions et notations du cadre proposé par Sarmiento (2025). Puis la section 4 introduit la contribution principale de ce travail : une fonction de coût modulaire permettant de paramétrer le choix des différentes composantes, des opérateurs et de l'évaluation normative. Enfin, nous concluons avec la présentation de la seconde contribution : un parseur permettant de passer d'un problème PDDL à notre formalisme dans la partie 5. Nous proposons ensuite une évaluation expérimentale de notre approche sur un exemple concret dans la section 6. À partir d'un problème PDDL, nous construisons un LTS afin de l'intégrer à notre méthode, puis nous expérimentons différentes configurations de la fonction de coût. Cette étude permet d'analyser les effets de ces différentes configurations et de mieux comprendre l'influence respective de ses différentes composantes.

2 État de l'art

Cet état de l'art présente les différents domaines explorés au cours de mon stage. La complexité de ce travail a résidé notamment dans la nécessité de préciser la définition et l'usage exact des outils mobilisés, issus de différents champs de recherche.

Nous présentons d'abord le domaine de la causalité effective, ainsi que celui du raisonnement sur l'action et le changement. Nous abordons ensuite le concept d'explication contrefactuelle : sa définition, ses limites, ainsi que les critères permettant de sélectionner les contrefactuels les plus pertinents. Nous terminons enfin sur la distinction entre causalité et responsabilité causale, et sur le rôle que jouent les normes, notamment mises en évidence par les sciences cognitives, dans le processus de sélection causale.

2.1 Causalité effective

La causalité peut être définie comme l'étude de l'influence par laquelle un événement, un processus ou un état (la cause) contribue à la production d'un autre événement, processus ou état (l'effet). Issu de la philosophie, les champs de recherche et d'applications de la causalité sont très variés. On y trouve par exemple la physique, l'économie, l'éthique, l'informatique ou encore le droit. Il existe deux types de causalité (Sarmiento Lozano 2024) : la première est la causalité générale qui cherche à définir des lois universelles, qui peut être vue comme une réflexion "vers l'avant", où l'on cherche à déterminer les effets de causes. On peut par exemple penser à des règles générales comme les lois de Newton qui permettent d'expliquer le mouvement d'objets, ou encore le fait que conduire en état d'ébriété augmente le risque d'accident.

À l'inverse se trouve la causalité effective qui, elle, correspond à une réflexion "vers l'arrière" : on cherche à définir les causes d'un effet dans des situations précises. Imaginons par exemple la situation suivante : Billy provoque un accident de voiture après avoir consommé de l'alcool et regardé son téléphone en conduisant. Contrairement à la causalité générale, les approches par causalité effective ne concluront pas forcément que c'est la consommation d'alcool qui a causé l'accident, mais plutôt la présence d'un animal sur la voie combinée à l'utilisation du téléphone par le conducteur de la voiture. La causalité effective consiste à retracer les chaînes causales propres à cette situation particulière. C'est à cette dernière que l'on s'intéresse dans ce travail.

Il existe deux approches principales en causalité effective : la première est l'approche par régularité qui se base uniquement sur les faits observés en établissant des relations causales sur des successions systématiques et prévisibles de causes et d'effets. Par exemple Hume définit un lien causal si la cause est continue à l'effet, qu'elle précède l'effet et qu'ils sont du même type (Hume 1748). Ce type de définition permet d'établir que le jour cause la nuit, ce qui met en évidence les limites de cette approche : bien que simple, elle demeure floue et insuffisante (Kueffner 2021). La seconde approche est l'approche contrefactuelle qui explore des mondes alternatifs régis par les mêmes lois que le monde observé, mais où des choses se sont produites différemment. Par exemple, si on se demande si A est la cause de B, on se demande si B se serait produit si A ne s'était pas produit : une cause est vue comme quelque chose qui fait la différence. Même si ces théories ont l'avantage d'être relativement intuitives et permettent de résoudre la majorité des situations auxquelles elles sont confrontées, sur certains cas des débats subsistent et parmi eux les cas de surdétermination. Un exemple simple est celui d'un marcheur dans le désert : une première personne empoisonne sa gourde puis une seconde la vide, le marcheur décède. Si on enlève l'empoisonnement le marcheur meurt quand même, de même si on ne vide pas sa gourde.

De tels cas nécessitent le développement de formalismes rigoureux permettant de représenter explicitement les relations causales et de raisonner sur des situations hypothétiques. Parmi les plus populaires d'entre eux, on trouve les modèles d'équations structurelles (*Structural Causal Model*, SCM) introduit notamment par Judea Pearl (Pearl 2009). Ces modèles permettent de modéliser le monde et les mécanismes causaux qui le régissent avec un ensemble de variables exogènes (dont les valeurs sont définies à l'extérieur du modèle) et un ensemble de variables endogènes dont les valeurs sont fixées par un ensemble d'équations structurelles déterministes. Dans ce formalisme, la

méthode de Halpern-Pearl définit les causes effectives comme l'ensemble des événements satisfaisant trois critères (Halpern 2016) : le premier est celui d'existence, selon lequel les événements doivent être observés pour être considérés comme une cause. Le second est la contrefactualité : si la cause est absente et en gardant fixe un ensemble de variables témoins l'effet n'est pas observé. Enfin, un critère de minimalité garantit que la cause ne comprend que les événements qui en font partie intégrante. Dans ce cadre, l'inférence contrefactuelle ne consiste pas à imaginer un monde alternatif, mais à calculer les conséquences d'une modification d'une ou plusieurs variables tout en conservant les mécanismes causaux. On peut donc prédire des observations, estimer les effets d'intervention et raisonner sur des scénarios contrefactuels.

Le formalisme de Halpern-Pearl présente toutefois certaines limites ou a minima des points de discussion. Parmi ceux-ci, on peut notamment questionner le fait que tous les éléments de la modélisation soient des événements, sans distinction avec les états. Cela peut limiter la réflexion lorsqu'on cherche à évaluer moralement une situation. En philosophie, particulièrement dans les théories morales, que l'on peut désigner comme un cadre éthique, on évalue généralement un état en fonction du bien ou du mal (plus largement de certaines normes) alors qu'évaluer les événements correspond à évaluer le fait qu'ils soient obligatoires, interdits ou optionnels (Sarmiento et al. 2023). Les modèles d'équations structurelles peuvent aussi poser un problème sur la difficulté qu'il peut y avoir à construire un modèle pertinent, que ce soit sur le choix des variables ou les définitions des équations qui les relient ainsi que sur la gestion des dépendances causales implicites. Enfin la sélection de l'intervention contrefactuelle est aussi un point de discussion : en fonction de ce choix les conclusions de l'analyse causale peuvent différer (D'Amico 2026). Ces limites soulignent que l'étude de la causalité ne peut être dissociée de la représentation des actions, des interventions et de l'évolution des états du monde. Le domaine du raisonnement sur l'action et le changement aborde précisément ces questions en proposant des formalismes dédiés à la modélisation des systèmes dynamiques.

2.2 Raisonnement sur l'action et le changement

Le raisonnement sur l'action et le changement (*Reasoning About Action and Change*, RAC) a pour objectif de modéliser et de raisonner sur les effets des actions, l'évolution des états du monde ainsi que les relations causales qui gouvernent ces évolutions (Saint-Cyr et al. 2014). Le modèle le plus courant du domaine est le système de transition d'états étiquetés (LTS), qui peut être instancié par différents langages d'actions. Un système de transition d'états étiquetés se compose de deux parties. La première représente l'état du monde par un ensemble de variables, chaque état étant caractérisé par un ensemble de fluents, c'est-à-dire des variables dont la valeur peut varier d'un état à l'autre. La seconde partie définit les transitions entre états du monde qui font évoluer le système. Elle définit les effets des événements ainsi que leurs préconditions.

Contrairement aux SCM, les LTS établissent donc clairement une distinction entre les états et les événements. Une autre divergence réside dans l'identification des chaines causales. En effet, ces concepts ne sont pas présents par construction dans les LTS et nécessitent une définition formelle et adaptée comme proposé par Sarmiento et al. (2023). Sarmiento Lozano (2024) propose une définition de cause effective adaptée aux LTS basée sur un test NESS (*Necessary Element for the Sufficiency of a Set*), test issu du droit pénal proposé par Wright (1985). Cette approche définit une cause comme "un élément nécessaire au sein d'un ensemble de conditions existantes qui était lui-même suffisant pour produire l'effet". Nous ne rentrerons pas ici dans les détails de ce test et ses avantages sur la méthode deHalpern-Pearl. L'idée est de montrer que le formalisme choisi est assez expressif pour l'étude de la causalité et permet de contourner les problèmes d'interventionnisme liés à la méthode de Halpern-Pearl.

Le processus d'identification des causes effectives d'une situation permet d'expliquer pourquoi un état particulier a été atteint ou, au contraire, pourquoi certaines situations ne se sont pas produites. Cette notion est particulièrement importante dans le contexte de l'explicabilité des systèmes décisionnels.

2.3 Explication contrefactuelle

Le domaine de l'explicabilité en intelligence artificielle (XAI) regroupe un ensemble de méthodes permettant d'expliquer le comportement ou les décisions prises par des systèmes intelligents. Parmi les familles de méthodes, les explications contrefactuelles occupent une place importante en raison de leur caractère intuitif et de leur proximité avec le raisonnement humain (Guidotti 2024). Une explication contrefactuelle répond à une question de la forme : "qu'aurait-il fallu changer pour obtenir un résultat différent ?". Au lieu d'expliquer directement une décision, les explications contrefactuelles identifient un changement minimal à effectuer sur l'entrée pour changer la sortie. Un lien naturel apparaît entre les explications contrefactuelles et le cadre du raisonnement contrefactuel en causalité, où l'on étudie les conséquences d'une intervention hypothétique tout en gardant les mécanismes causaux du système (Pearl 2009).

Les explications contrefactuelles sont majoritairement des explications locales qui répondent à une situation particulière, bien qu'il existe des explications globales qui permettent de caractériser le comportement général d'un système. Il existe aussi différents types d'explications contrefactuelles : les suffisantes et les nécessaires. Les explications nécessaires identifient les parties de l'entrée qui doivent être modifiées pour changer la sortie. A contrario les explications suffisantes identifient les valeurs des caractéristiques de l'entrée qui permettent de directement changer la sortie (Amgoud et Cooper 2026). Une des difficultés avec les explications contrefactuelles est l'absence d'unicité de l'explication : plusieurs interventions peuvent changer le résultat. C'est pour cette raison que la littérature propose un large choix de critères permettant de sélectionner les explications les plus pertinentes en fonction de l'application, tels que l'actionnabilité, la robustesse, la proximité...(Verma et al. 2022). Ces critères doivent être adaptés en fonction de la nature du système qui produit le résultat (apprentissage supervisé, apprentissage par renforcement, modèles profonds...).

Si les méthodes d'explications contrefactuelles sont particulièrement nombreuses pour les modèles d'apprentissage supervisé, plusieurs travaux se sont intéressés à des applications dans des systèmes de décisions séquentiels comme les *Markov Decision Processes* et l'apprentissage par renforcement. L'application à ce sous-domaine de l'IA demande de prendre en compte des spécificités particulières comme la dimension temporelle, la fonction de récompense, les plans, les événements... (Gajcin et Dusparic 2024). De plus en apprentissage supervisé une hypothèse d'indépendance entre les instances est faite. Cette hypothèse n'est pas applicable pour l'apprentissage par renforcement, car les états sont temporellement dépendants, et une redéfinition des critères est donc nécessaire (Gajcin et Dusparic 2024).

En apprentissage par renforcement, la nature même de l'explication contrefactuelle peut être discutée : contrairement à l'apprentissage supervisé, où l'explication prend naturellement la forme d'un objet du même type que l'entrée (on modifie les caractéristiques d'une instance), une action seule n'a pas vraiment de sens en dehors de la politique qui l'a produite. C'est pourquoi les explications contrefactuelles en apprentissage par renforcement prennent le plus souvent la forme de politiques contrefactuelles, comme dans (Dong, Zhang et Feng 2025). Un des enjeux principaux reste alors la robustesse de ces politiques à la stochasticité de l'environnement et aux mécanismes causaux implicites (Buesing et al. 2018 ; Lally, Kazemi et Paoletti 2026), des questions qui représentent des enjeux extérieurs au cadre du travail proposé.

2.4 Responsabilité et sélection causale

Il est important d'apporter une précision pour lever une confusion fréquente : on peut s'interroger sur la cause d'un effet, mais aussi sur la responsabilité d'une cause dans la production de cet effet (Hart 1978). Un exemple permet de distinguer la causalité de la responsabilité causale : imaginons un pont ne pouvant supporter qu'un véhicule à la fois, sous peine de s'effondrer. Tom s'engage sur le pont alors que son feu est vert, en face Luc s'engage alors que son feu est rouge. Le pont s'effondre. D'un point de vue purement causal, Tom et Luc sont tous deux à l'origine de l'effondrement, car leur présence simultanée est nécessaire à la production de l'effet. Cependant, on a souvent tendance à attribuer la responsabilité de l'accident à Luc, parce qu'il n'avait pas à passer au feu rouge. Ce

raisonnement relève de la responsabilité causale et non de la causalité au sens strict. La responsabilité causale est soumise à des considérations qui peuvent être morales, statistiques ou prescriptives qui dépassent la relation simple de cause à effet. Ces considérations jouent un rôle particulièrement important dans le raisonnement contrefactuel qui constitue le cœur de ce travail.

Le raisonnement contrefactuel vise à explorer des mondes hypothétiques afin d'identifier ceux qui sont les plus pertinents à comparer au monde observé. Cette comparaison permet de déterminer quels facteurs font effectivement la différence dans la production d'un effet. Intégrer les normes dans cette exploration est pertinent, car elles orientent naturellement la recherche vers des alternatives cohérentes et plausibles. Dans le cas du pont, si l'on s'interroge sur la manière dont les choses auraient pu se dérouler différemment pour éviter l'accident, on aura tendance à privilégier certains mondes contrefactuels. En particulier, on considérera plus volontiers le monde dans lequel Luc respecte le feu rouge. Celui-ci semblera plus plausible que le monde dans lequel Tom, bien qu'étant en règle, renonce à s'engager.

Si ces choix sur les situations contrefactuelles considérées peuvent paraître subjectifs, des travaux en sciences cognitives montrent qu'ils obéissent en réalité à des régularités empiriques. De nombreuses recherches se sont intéressées au processus cognitif de sélection causale, par lequel un ou plusieurs éléments d'une structure causale complexe sont désignés comme les causes réelles d'un effet donné (Reuter et al. 2014), et notamment à la manière dont les normes statistiques, temporelles ou prescriptives influencent ce processus. Même s'il est essentiel de ne pas confondre les concepts de sélection causale et de causalité pure, il est pertinent d'intégrer ces normes dans ce travail, car elles permettent de restreindre l'espace des mondes possibles à considérer lors du raisonnement contrefactuel. Les sciences cognitives ont montré que la force causale attribuée à un événement dépend de son caractère plus ou moins normatif (Icard, Kominsky et Knobe 2017). Elles ont aussi mis en évidence que les individus ont tendance à construire des scénarios contrefactuels en modifiant les événements les plus récents. En revanche, dans des cas de surdétermination, un poids causal plus important est attribué au premier événement suffisant à la production de l'effet. Un développement plus détaillé de ces résultats est présenté en annexe (voir annexe D).

De nombreux modèles ont été proposés afin d'expliquer ces différents phénomènes, mais leurs hypothèses respectives, ainsi que les nuances qui les distinguent, restent difficiles à comparer formellement. Ce travail propose précisément d'intégrer, au sein d'un même cadre formel, des concepts issus de la littérature en sciences cognitives, pour en évaluer la cohérence et rendre possible la comparaison. Cette formalisation permet également d'identifier les facteurs qui constituent des cibles pertinentes d'intervention dans le monde observé, c'est-à-dire ceux dont la modification est susceptible d'affecter l'état normatif du système, la normativité étant comprise comme la conformité à nos attentes (D'Amico 2026).

3 Définitions et notations

On définit dans un premier temps l'ensemble des objets nécessaires à l'évaluation des contextes causaux contrefactuels. Une partie des définitions est directement extraite de l'article de Sarmiento 2025, d'autres ont été légèrement modifiées et certaines ont été ajoutées.

On commence par décrire la structure du monde : les fluents qui le caractérisent ainsi que les formules d'états qui permettent d'exprimer des propriétés logiques sur ces fluents.

- $\mathbb{F}$: ensemble de fluents qui décrivent l'environnement
- $\mathcal{F}$: ensemble des formules d'état, formules de logique propositionnelle construites sur $\mathbb{F}$. Formellement :

$$\psi \coloneqq f \mid \top \mid \bot \mid \neg\psi \mid \psi \vee \psi \mid \psi \wedge \psi, \quad f \in \mathbb{F} \tag{1}$$

- $\mathbb{S} \subseteq 2^{\mathbb{F}}$: ensemble de tous les états possibles du monde

On introduit ensuite la dynamique du monde, à travers les événements qui font évoluer le monde et les relations de transition qui les relient aux états, formant ainsi un système de transition d'états étiquetés (LTS).

- $\mathbb{E}$: ensemble des variables qui décrivent les transitions, "*ground events*" qui modifient les fluents
- $\tau \subseteq \mathbb{S} \times 2^{\mathbb{E}} \times \mathbb{S}$: ensemble des relations de transition. Pour chaque état τ indique les ensembles d'événements simultanés qui pourraient se produire ainsi que les états résultants
- **Labelled Transition System**, $\langle \mathbb{S}, \tau \rangle$: graphe orienté avec $\mathbb{S}$ les nœuds du graphe et τ les arcs du graphe. *Remarque* : cette définition conventionnelle d'un graphe (nœuds + arcs) permet aussi de garder l'information d'états qui n'ont pas de transition entrante ou sortante. Soit $pre : \mathbb{E} \to \mathcal{F}$, la fonction qui à chaque événement associe ses préconditions. Celles-ci sont exprimées sous la forme de formules d'état et donnent les conditions qui doivent être respectées dans un état pour qu'un événement puisse se produire. On considère dans notre contexte que tous les LTS sont corrects relativement à cette fonction. Formellement :

$$\forall (S, E, S') \in \tau, \quad \forall e \in E, \quad S \models pre(e)$$

Une fois cette structure posée, on définit la notion de politique qui associe à chaque état un événement à réaliser, ainsi que la notion de contexte causal, qui associe une politique et un état de départ dans un LTS donné.

- **Politique** $\pi : \mathbb{S} \to 2^{\mathbb{E}}$ relativement à un LTS donné. À la différence du modèle de Sarmiento (2025) les événements ne dépendent que d'un état et non d'un couple (état, temps). On considère dans notre cadre que les états contiennent l'ensemble des informations nécessaires, ce qui peut inclure des informations implicites sur le temps.
- Π_τ l'ensemble de toutes les politiques possibles relativement à un LTS $\langle \mathbb{S}, \tau \rangle$.
- **Politique correcte** π relative à un LTS, c'est-à-dire telle que :

$$\forall S \in \mathbb{S} \quad \exists S' \in \mathbb{S}, (S, \pi(S), S') \in \tau.$$

- **Contexte causal** : $\chi = (\pi, S_0, \tau)$ avec $\pi \in \Pi_\tau$ une politique, $S_0 \in \mathbb{S}$ un état de départ et τ un ensemble de relations de transitions décrivant un LTS.
- **Contexte causal contrefactuel** : soit $\chi = (\pi, S_0, \tau)$ un contexte causal observé. On appelle contexte causal contrefactuel relatif à χ tout contexte causal $\chi' = (\pi', S_0', \tau)$ construit sur le même LTS $\langle \mathbb{S}, \tau \rangle$, tel que $\pi' \neq \pi$ ou $S_0' \neq S_0$. Un contexte causal contrefactuel représente un scénario alternatif à un scénario observé, obtenu soit en modifiant la politique suivie, soit l'état de départ, soit les deux, tout en conservant les mêmes lois causales du monde (le LTS étant inchangé).
- Hypothèse déterministe : un LTS défini par $\langle \mathbb{S}, \tau \rangle$ est dit déterministe si :

$$\forall S, S' \in \mathbb{S}, \forall E \in 2^{\mathbb{E}}, \quad (S, E, S') \in \tau \implies \nexists S'' \in \mathbb{S}, \quad (S, E, S'') \in \tau, \quad S'' \neq S'.$$

- **États terminaux** $\mathbb{A} \subseteq \mathbb{S}$: ensemble des états d'un LTS $\langle \mathbb{S}, \tau \rangle$ défini par :

$$\mathbb{A} = \{S \in \mathbb{S} \mid \ (S, \emptyset, S) \in \tau\} \qquad \text{et} \quad \forall S' \notin \mathbb{A}, \ \forall E \in 2^{\mathbb{E}}, \quad E \neq \emptyset, \quad (S', E, S') \notin \tau.$$

L'exécution d'un contexte causal engendre une évolution du monde qu'il est nécessaire de pouvoir indexer temporellement, on introduit pour cela l'ensemble des pas de temps, qui permet de définir les fonctions S^χ et E^χ donnant l'état et l'événement obtenus à un instant donné, ainsi que la trace σ^χ. Les résultats de S^χ, E^χ ainsi que la trace sont directement calculables de par le fait que les LTS ainsi que les politiques sont déterministes.

- $\mathbb{T}$: ensemble des pas de temps
- $S^\chi : \mathbb{T} \to \mathbb{S}$ la fonction relative à un contexte causal $\chi = (\pi, S_0, \tau)$ qui indique au pas de temps $t \in \mathbb{T}$ l'état dans lequel on se trouve en suivant la politique π, dans τ depuis S_0.

- $E^{\chi} : \mathbb{T} \to \mathbb{E}$ la fonction relative à un contexte causal $\chi = (\pi, S_0, \tau)$ qui indique au pas de temps $t \in \mathbb{T}$ l'événement qui a lieu en suivant la politique π, dans τ depuis S_0
- **Trace** σ^{χ} : avec $\chi = (\pi, S_0, \tau)$, la trace complète (états, événements), obtenue dans le contexte causal χ, de la forme : $[S_0, E_0, S_1, E_1, \ldots, E_{n-1}, S_n, E_n, S_n, E_n \ldots]$. Une fois un état terminal atteint, on observe une boucle qui donne une trace infinie. On simplifie cette trace pour qu'elle soit de longueur finie. Soit n tel que $S_n \in \mathbb{A}$: la trace d'origine devient $\sigma^{\chi} = [S_0, E_0, S_1, E_1, \ldots, E_{n-1}, S_n]$. On notera $\sigma^{\chi}_{|state}$ la partie de la trace ne contenant que les états et $\sigma^{\chi}_{|event}$ la trace ne contenant que les événements.

Enfin, on introduit la fonction $expert_judge_{\tau}$, qui permet de représenter la notion de normativité dans le formalisme. On pondère les transitions du LTS avec des poids qui représente le respect ou la violation d'une norme.

- $expert_judge_{\tau} : \mathbb{S} \times 2^{\mathbb{E}} \to [0, 1]$ fonction d'évaluation experte, définie partiellement sur l'ensemble des couples (S, E) tel que $\exists S' \in \mathbb{S}, (S, E, S') \in \tau$. Cette fonction attribue à chaque paire une valeur comprise entre 0 et 1 relative à une norme (statistique ou prescriptive).

Les éléments présentés dans cette section forment un cadre de travail clair et expressif, sur lequel je m'appuie dans la section 4 pour introduire la contribution principale de ce travail. Un exemple d'instanciation avec ces notions se trouve dans la section 6.

4 Évaluation d'un contexte causal contrefactuel

Pour évaluer un contexte causal contrefactuel relativement à un contexte causal observé, on procède en deux temps. Dans un premier temps, on attribue à chaque contexte causal contrefactuel un coût, qui permet à la fois d'évaluer sa proximité à l'observation et sa plausibilité relativement à une norme. Cette fonction de coût, définie sur l'ensemble des contextes causaux contrefactuels permet de les ordonner entre eux. Elle joue aussi un rôle de filtre a priori en attribuant un coût infini aux contrefactuels non valides relativement au LTS, par exemple, ceux dont la politique ne diverge de la politique observée qu'en des états absents de la trace observée.

La fonction de coût est une mesure de qualité des contrefactuels, mais on peut également vouloir restreindre cette notion à un sens plus proche de celui employé en XAI. C'est pourquoi dans un second temps, on définit un filtre a posteriori qui, une fois les contextes causaux évalués, ne retient que ceux dont l'état final diffère de celui observé (validité au sens XAI), et dont le coût reste inférieur à un certain seuil d'acceptabilité.

Dans la partie qui suit, j'introduis la fonction de coût proposée, puis je détaille les termes qui la composent avant de conclure par les filtres a posteriori.

4.1 Fonction de coût proposée

La fonction de coût doit permettre d'atteindre un compromis entre l'évaluation :

- de la distance du contexte causal contrefactuel par rapport au causal setting observé. L'intuition derrière ce terme correspond à l'idée qu'un bon contrefactuel doit être relativement proche du contexte causal observé pour être pertinent ;
- de la plausibilité du contexte causal. La plausibilité ou réalisme correspond ici à un respect relatif d'une norme (statistique ou prescriptive).

La fonction de coût intègre deux termes supplémentaires qui permettent d'exclure les contrefactuels non valides relativement au LTS (politiques non correctes), ainsi que les politiques qui ne divergent de la politique observée que sur des états non présents dans la trace d'états observée.

Aussi, la fonction globale, dont les composantes sont discutées tour à tour dans les sections suivantes, s'écrit :

$$Coût_\tau(\chi, \chi') = \lambda_1 d_obs(\sigma^{\chi}_{|state}, \sigma^{\chi'}_{|state}) + \lambda_2 v(\chi', expert_judge_\tau) + divergence(\chi, \chi') + correct(\chi') \tag{2}$$

avec :

- $\chi = (\pi, S_0, \tau)$ le contexte causal observé et $\chi' = (\pi', S'_0, \tau)$ le contexte causal contrefactuel que l'on évalue,
- d_obs attribue un coût relatif à la distance entre le contexte causal contrefactuel par rapport à celui observé. Je propose d'utiliser la distance de Levenshtein sur la trace des états, avec une variation des poids en fonction du type de l'intervention effectuée (suppression, insertion, substitution) ;
- v la fonction de vraisemblance du contexte causal contrefactuel par rapport à un jugement expert ;
- la fonction *divergence* permet d'exclure les contextes causaux contrefactuels si leur politique associée ne diverge de celle observée que dans des états non présents dans la trace d'états du contexte causal observé :

$$divergence(\chi, \chi') = \begin{cases} 0 \quad \text{si} \quad \exists t < len(\sigma^{\chi}_{|state}) \quad \pi(S^{\chi}(t)) \neq \pi'(S^{\chi}(t)) \\ +\infty \quad \text{sinon} \end{cases} \tag{3}$$

  Voir l'exemple dans l'annexe A.1 ;
- la fonction *correct* permet d'exclure les contextes causaux contrefactuels dont la politique n'est pas correcte :

$$correct(\chi') = \begin{cases} 0 \quad si\ \pi'\ correcte\ relativement\ au\ LTS\ associé\ à\ \tau \\ +\infty \quad sinon \end{cases} \tag{4}$$

  Voir l'exemple dans l'annexe A.2.

Les termes d_obs et v sont des termes bornés et permettent d'ordonner les contextes causaux contrefactuels. Les termes *divergence* et *correct* valent 0 ou $+\infty$ et jouent un rôle de filtre à priori, séparé de l'évaluation quantitative.

4.2 Distance à l'observation

Cette section présente la manière dont est défini et calculé la distance entre un contexte causal contrefactuel et le contexte observé. Le choix de la distance de Levenshtein est d'abord présenté, avant d'aborder la manière dont elle est enrichie pour tenir compte de la mutabilité des états.

4.2.1 Distance de Levenshtein

Pour évaluer la distance entre deux contextes causaux, on choisit de travailler sur leurs traces d'états qui sont finies et entièrement déterminées par les contextes causaux. Une trace d'états peut être vue comme un mot défini sur un alphabet dont les lettres sont les états du LTS.

La distance de Levenshtein est utilisée pour comparer deux chaînes de caractères. Elle indique le coût minimal des opérations pour transformer l'une en l'autre. Les opérations sont l'insertion, la suppression et la substitution d'un caractère. Appliquée aux traces d'états, elle correspond au coût minimal des interventions nécessaires pour passer de la trace contrefactuelle à la trace observée, ou inversement. Ce choix de la distance de Levenshtein présente plusieurs intérêts pour notre application. D'une par cette distance ne suppose pas de contrainte sur la longueur des traces comparées, ce qui est essentiel car une politique contrefactuelle peut produire une trace plus longue, plus courte que celle du contexte observé ou de longueur égale. D'autre part, elle décompose la distance

en somme d'opérations élémentaires interprétables (insertion, suppression, substitution d'un état). Cette décomposition peut être exploitée en modifiant la pondération de chaque opération, comme illustré dans la section suivante.

4.2.2 Intégration de la mutabilité

Des travaux en sciences cognitives ont montré l'importance des notions de propensité (vraisemblance d'obtenir un effet sachant qu'un événement se produit) et de mutabilité (facilité avec laquelle on peut imaginer qu'un événement ait été différent) des événements lors du processus de raisonnement contrefactuel pour la sélection causale (McGill et Tenbrunsel 2000) (voir les détails en annexe D.1). Notre cadre est pour l'instant déterministe donc nous laissons de côté la notion de propensité. Cependant, il reste intéressant d'intégrer la mutabilité, notamment pour le calcul de la distance à l'observation, la première étape étant d'adapter les définitions du concept en sciences cognitives à notre cadre.

Soit un état S d'un LTS défini par $< \mathbb{S}, \tau >$, on définit sa mutabilité de la façon suivante :

$$mutabilite(S) = Card\{(S, E', S') \in \tau\}. \tag{5}$$

La mutabilité correspond ainsi au nombre d'arcs sortant de l'état de départ d'un événement. Pour un état donné, s'il possède un grand nombre d'arcs sortants, on considère ses événements possibles comme très mutables (on peut facilement imaginer qu'un autre événement ait eu lieu). Le coût de substitution d'un état de la trace observée par un autre état correspond à l'inverse de la mutabilité de l'état le précédant dans la trace observée :

$$coût_substitution(S) = \frac{1}{mutabilite(S_{\text{précédent}})} \tag{6}$$

On observe dans la Figure 1 l'intérêt de modifier le coût de substitution en fonction de la mutabilité : s'il avait été fixé à un, la distance à l'observation pour les traces rouge et bleue aurait été la même. Cependant, on considère maintenant plus proche une trace contrefactuelle si elle diffère en des états très mutables de la trace observée. Tenir compte de la mutabilité permet de privilégier l'une par rapport à l'autre et donc de fournir une évaluation plus fine des contextes causaux contrefactuels

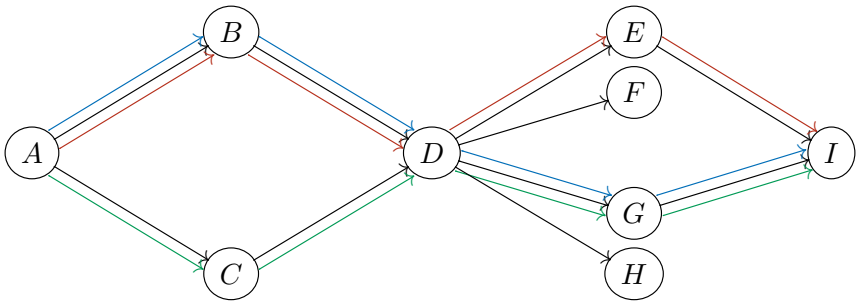


Figure 1 – Exemple d'application de la distance de Levenshtein avec un coût de substitution dynamique : dépendant de la mutabilité des états. Avec un coût de substitution fixé à 1, on obtient *coût*(ABDEI, ABDGI) = 1 = *coût*(ACDGI, ABDGI). En tenant compte de la mutabilité des états, on obtient *coût*(ABDEI, ABDGI) = $\frac{1}{4}$ < *coût*(ACDGI, ABDGI) = $\frac{1}{2}$, car *mutabilité*(A) = 2 < *mutabilité*(D) = 4.

Un enrichissement pourrait être de définir un coût de substitution ne dépendant pas uniquement de la caractéristique de l'état précédent mais aussi de l'état remplaçant l'état courant.

4.3 Vraisemblance du contrefactuel

L'évaluation de la vraisemblance d'un contexte causal se fait relativement à une norme. Pour tenir compte de cet aspect normatif, on choisit de représenter une norme sous la forme d'une pondération des transitions, qui par défaut est considérée comme fournie par un expert, d'où le nom *expert_judge* (équation 3). Cette évaluation attribue un score compris entre 0 et 1 à chaque couple (état, événement) d'un LTS. Un score de 1 correspond à un respect total de la norme, un score de 0 à un non-respect total de la norme. Différentes contraintes peuvent être envisagées pour l'attribution des scores, et sont discutées dans la section 4.3.1. Une fois la pondération du graphe établie il faut définir concrètement une définition de la vraisemblance. Le cadre des LTS et des contextes causaux est très riche et les objets considérés pour évaluer la vraisemblance peuvent être divers. J'introduis dans la section 4.3.2 une évaluation basée sur la comparaison entre la politique associée au contexte causal contrefactuel et une politique optimale. Dans la section 4.3.3, une seconde proposition est faite, où l'on utilise la trace du contexte causal contrefactuel pour en évaluer la vraisemblance relativement à la norme.

4.3.1 Pondération des arcs

Différentes méthodes sont possibles pour attribuer les poids des transitions et leur choix entraîne plusieurs questions qu'il me semble important d'expliciter afin d'en saisir les nuances ainsi que les difficultés auxquelles on se confronte lorsque l'on cherche à modéliser une norme. Je présente dans ce qui suit trois choix qui ont été envisagés : contraindre à une distribution de probabilité les scores sortant d'un même état, contraindre à une distribution de possibilité ou attribuer des valeurs libres. Ce choix peut se faire en fonction de ce que l'on souhaite représenter ou en fonction des informations disponibles.

Distribution de probabilité On peut choisir de contraindre les scores des transitions sortant d'un même état à une distribution de probabilité. Deux constructions sont possibles : la première consiste à partir d'un classement des événements et le convertir en distribution à l'aide d'un *softmax* sur l'inverse des positions. Cette méthode a l'avantage de sa simplicité, il est plus facile d'ordonner des événements que de leur attribuer un score exact. Toutefois avoir un ordre strict n'est pas toujours possible (certains événements peuvent être normativement équivalents). Elle souffre d'une perte d'expressivité, car les écarts entre événements sont fixés par le nombre d'arcs sortant de l'état plutôt que par une différence normative réelle. Une seconde construction consiste à demander directement à l'expert une distribution de probabilité sur les événements sortant d'un état. Cette méthode permet de limiter la perte d'expressivité et autorise l'attribution de scores égaux. Elle présente cependant l'incovéniant propre à toute distribution de probabilité imposant une somme de tous les scores égale à 1. Cela pénalise mécaniquement les événements issus d'un état comportant de nombreux arcs sortants comme l'illustre la figure 2.

Distribution de possibilité On peut à la place d'une distribution de probabilité envisager une distribution de possibilité. L'hypothèse du monde clos impose que le score maximal parmi les événements sortant d'un état soit égal à 1, sans contraintes sur la somme des scores. Cette approche permet de ne plus avoir une pénalisation par rapport au nombre d'arcs sortants tout en conservant une forme de normalisation, mais elle suppose que l'ensemble des événements sortants représentés dans le LTS est exhaustif et qu'aucun événement extérieur ne pourrait représenter une alternative pleinement satisfaisante.

Valeurs libres Une troisième option consiste à abandonner toute contrainte entre les événements d'un même état, en demandant à l'expert de juger chaque événement indépendamment des autres. Cette approche a l'avantage de ne pas avoir les inconvénients présentés précédemment mais elle déplace la difficulté sur l'expert. Sans contraintes structurelles, l'interprétation et le choix à travers l'ensemble des valeurs du LTS se complexifie.

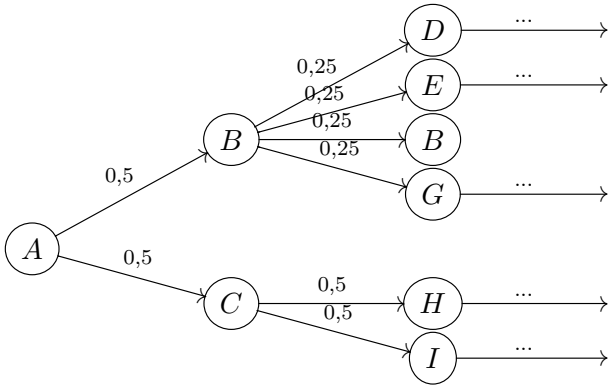


FIGURE 2 – Exemple de LTS pondéré par des distributions de probabilité. Pour les états B et C chaque événement sortant est normativement équivalent aux autres. Les arcs sortants de l'état B sont pénalisés par leur nombre.

4.3.2 Évaluation de la vraisemblance à partir d'une politique optimale

Une fois le LTS pondéré, on cherche à évaluer la plausibilité du contexte causale contrefactuel. Une première possibilité est de travailler au niveau des politiques. On définit dans un premier temps une politique optimale. Puis, on définit une mesure de divergence entre la politique du contexte causal contrefactuel et cette politique optimale.

Construction d'une politique optimale à partir des scores

La construction de politiques optimales peut être contrainte selon l'application, en fonction d'une heuristique, en prenant en compte le coût de calcul de la construction, etc. Les politiques optimales dépendent uniquement d'un LTS et de l'évaluation d'un juge expert. Elles ne font intervenir ni la politique contrefactuelle ni l'état initial du contexte causal contrefactuel et elles peuvent être construites une seule fois puis réutilisée pour évaluer plusieurs contextes contrefactuels. On distingue ici deux façons de construire une politique optimale : sans et avec planification.

1. Politique optimale sans planification : pour chaque état cette politique indique l'événement qui maximise l'évaluation de l'expert à un horizon temporel d'un seul pas de temps. La fonction $\pi_\tau^{opt} \in \Pi_\tau$ est définie par :

$$\forall S \in \mathbb{S} \quad \pi_\tau^{opt}(S) = \underset{E \in 2^{\mathbb{E}}}{\operatorname{argmax}}(expert_judge_\tau(S, E)) \tag{7}$$

   Cette politique a pour avantage sa simplicité de construction, d'interprétation ainsi que son coût de calcul. L'utilisation d'un *argmax* peut mener à des égalités : dans les cas où plusieurs événements maximisent le score, on peut appliquer une seconde heuristique ou choisir aléatoirement. Elle possède également d'autres limitations, comme on l'observe dans l'exemple de la figure 3.

   La politique optimale sans planification associée au LTS de la figure 3 correspond à :

$$\begin{aligned} &\pi_\tau^{opt1}(S_0) = a, \quad \pi_\tau^{opt1}(S_1) = a, \quad \pi_\tau^{opt1}(S_2) = b, \\ &\forall i \in [3,4,5,6] \quad \pi_\tau^{opt1}(S_i) = \emptyset \end{aligned} \tag{8}$$

   Si on fixe l'état de départ à S_0 on obtient, en suivant la politique optimale, la trace $[S_0, a, S_1, a, S_3]$ qui correspond au chemin rouge. La moyenne arithmétique des scores des événements de cette

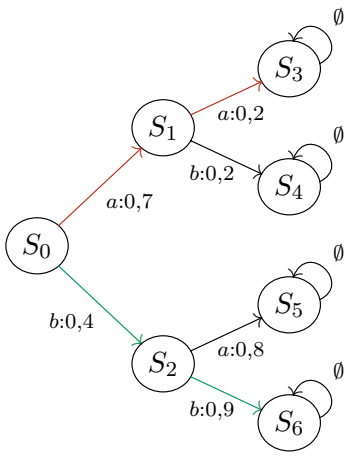


FIGURE 3 – Exemple de LTS évalué par un expert qui représente un cas limite pour une politique sans planification. Étiquetage des arcs du graphe de la forme "événement : score"

trace vaut 0.45 (le choix de la moyenne arithmétique est discutable). Cependant, on peut considérer dans ce cas que la bonne décision à prendre, à partir de l'état S_0, en connaissant le LTS et les scores qui y sont associés est l'événement b. En effet, on obtient la trace $[S_0, b, S_2, b, S_6]$, correspondant au chemin vert et qui a une moyenne arithmétique sur les scores des événements de la trace de 0.65.

De cet exemple, on tire deux observations. La politique optimale sans planification ne tire pas parti de la connaissance totale du LTS et des scores associés aux événements. Deuxièmement, on note que la politique optimale n'est pas unique. En effet, un choix arbitraire a été effectué en S_1 pour le choix de l'événement a.

2. Politique optimale avec planification : On peut généraliser l'équation 7 en prenant en compte, à chaque état, l'ensemble des chemins possibles plutôt que le seul pas de temps suivant. Pour cela, dans chaque état, on applique un algorithme du plus court chemin (par exemple A*) dans un graphe pondéré modifié et on sélectionne le premier événement de ce chemin. Voir l'annexe B pour plus de détails sur la construction de cette politique. Ce type de politique optimale permet de prendre en compte la connaissance totale du LTS et, en fonction de l'algorithme de plus court chemin, on peut limiter l'augmentation du coût de construction de la politique. Une telle politique permet de mieux gérer les cas du même type que celui de la figure 3. On obtient, par exemple pour le LTS de la figure 3, une politique de la forme :

$$\pi_\tau^{opt2}(S_0) = b, \quad \pi_\tau^{opt2}(S_1) = a, \quad \pi_\tau^{opt2}(S_2) = b, \quad \forall i \in [3,4,5,6] \quad \pi_\tau^{opt2}(S_i) = \emptyset \tag{9}$$

Comme pour les politiques optimales sans planification, il n'y a pas unicité du résultat. Un traitement spécifique est nécessaire pour les états qui possèdent plusieurs événements qui maximisent le score.

Mesure de divergence entre politiques À partir d'une politique optimale donnée, on peut définir un coût de vraisemblance entre cette dernière et la politique associée à un contexte causal contrefactuel. On définit une mesure de divergence entre deux politiques sur une trace d'états :

$$dist_politiques(\pi, \pi', \sigma_{|state}) = \frac{Card\{S \in \sigma_{|state} \mid \pi(S) \neq \pi'(S)\}}{Card\{S \in \sigma_{|state}\}}. \tag{10}$$

On peut utiliser cette mesure pour évaluer la vraisemblance entre une politique associée à un

contexte causal contrefactuel $\chi' = (\pi', S_0, \tau)$ et une politique optimale π_τ^{opt} construite à partir d'une évaluation experte $expert_judge_\tau$:

$$v(\chi', expert_judge_\tau) = dist_politiques(\pi', \pi_\tau^{opt}, \sigma^{\chi'}_{|state}) \tag{11}$$

Cette mesure revient à compter le nombre de fois où la politique contrefactuelle n'a pas effectué un choix optimal sur le chemin (la trace) obtenue dans son contexte causal.

Soit, le LTS $\langle \mathbb{S}, \tau \rangle$ de la figure 3. On définit un contexte causal $\chi' = (\pi', S_0, \tau)$ avec :

$$\pi'(S_0) = b, \quad \pi'(S_1) = b, \quad \pi'(S_2) = a, \quad \forall i \in [3,4,5,6] \quad \pi'(S_i) = \emptyset$$

On obtient la trace $\sigma^{\chi'} = [S_0, b, S_2, a, S_5]$ et donc $\sigma^{\chi'}_{|state} = [S_0, S_2, S_5]$

- Coût de vraisemblance avec π_τ^{opt1} :

$$dist_politiques(\pi', \pi_\tau^{opt1}, \sigma^{\chi'}_{|state}) = \frac{Card\{S_0, S_2\}}{Card\{S_0, S_2, S_5\}} = \frac{2}{3}$$

- Coût de vraisemblance avec π_τ^{opt2} :

$$dist_politiques(\pi', \pi_\tau^{opt2}, \sigma^{\chi'}_{|state}) = \frac{Card\{S_2\}}{Card\{S_0, S_2, S_5\}} = \frac{1}{3}$$

On observe que le résultat du coût de vraisemblance dépend de la politique optimale même si l'évaluation experte sur lesquelles π_τ^{opt1} et π_τ^{opt2} sont construites est la même.

4.3.3 Évaluation de la vraisemblance par agrégation de scores

Une autre approche possible pour évaluer la vraisemblance d'un contexte causal contrefactuel est de directement exploiter l'évaluation experte, en agrégeant les scores des événements associés à la trace du contexte causal contrefactuel. Pour cela différents opérateurs d'agrégation peuvent être utilisés en fonction de l'application.

Soit Agg un opérateur d'agrégation, un LTS $\langle \mathbb{S}, \tau \rangle$, un contexte causal contrefactuel $\chi' = (\pi', S_0, \tau)$ avec $\sigma^{\chi'} = [S^{\chi'}(0), E^{\chi'}(0), \ldots, E^{\chi'}(n-1), S^{\chi'}(n)]$ et $expert_judge_\tau$ une évaluation experte sur le LTS. La fonction v de l'équation 2 est de la forme :

$$\begin{aligned} &v(\chi', expert_judge_\tau) = 1 - Agg(s_0, \ldots, s_{n-1}) \\ &\forall i < len(\sigma^{\chi'}_{|state}) \quad s_i = expert_judge(S^{\chi'}(i), E^{\chi'}(i)) \end{aligned} \tag{12}$$

Pour déterminer quel opérateur d'agrégation choisir, on s'intéresse à différentes propriétés qu'un tel opérateur peut satisfaire : une invariance à la longueur de la liste des scores (implicitement du chemin), une pénalisation en fonction du temps, des possibilités de compensation, etc.

Opérateur de moyenne géométrique Dans la définition usuelle de cet opérateur, un score nul annule entièrement l'agrégation quelle que soit la valeur des autres scores ce qui en fait un agrégateur "partiel" de compensation. Il reste néanmoins intéressant, car il est plus sensible aux variations que la moyenne arithmétique, ce qui présente un intérêt lorsqu'on travaille sur des normes : on cherche alors à pénaliser les chemins présentant une forte disparité entre les scores. C'est pour cette raison que l'on introduit $\varepsilon > 0$ qui garantit que même un score très faible (voire nul) conserve une contribution non nulle à l'agrégation, permettant à l'opérateur de rester un opérateur de compensation sans

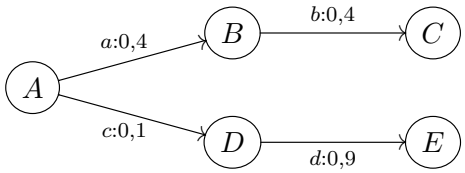
restreindre l'évaluation à des valeurs strictement supérieures à 0. Soit $\varepsilon > 0$:

$$agg_{geo}(s_0, s_1, \ldots, s_{n-1}) = \sqrt[n]{\prod_{i=0}^{n-1} \max(\varepsilon, s_i)} \tag{13}$$

Même s'il est un opérateur de compensation, pour "rattraper" un score faible, la compensation doit être plus forte qu'avec une moyenne arithmétique. Dans l'exemple suivant on cherche à "rattraper" le score 0.3 :

- $agg_{geo}([0.5, 0.3, 0.7]) = 0.47$ la moyenne arithmétique est bien de 0.5 mais, l'opérateur pénalise le faible score de 0.3 et renvoie une valeur inférieure
- $agg_{geo}([0.5, 0.3, 0.8]) = 0.5$ pour obtenir le même résultat qu'avec une moyenne arithmétique de 0.5 il faut ici un score de compensation plus élevé (0.8 au lieu de 0.7), ce qui correspond à une moyenne arithmétique supérieure (0.53).

On observe sur la figure 4 que le coût associé au chemin [ABC] est plus faible que celui du chemin [ADE] même si ce dernier possède une moyenne arithmétique plus élevée. En effet, la variance plus importante de [ADE] est pénalisée en utilisant la moyenne géométrique. Cette propriété est pertinente dans un cadre de travail avec des normes, car on préfère généralement une séquence d'actions stable et modérément bénéfique à une séquence composée d'actions fortement négatives suivie d'actions fortement compensatoires.



(a) LTS

chemin	1 - moyenne	1 - agg_{geo}
ABC	0.6	**0.6**
ADE	**0.5**	0.7

(b) Coûts

FIGURE 4 – Sensibilité de l'opérateur de moyenne géométrique

Opérateur gamma (temporel) Soit $\gamma \in]0, 1]$, $\Gamma = \frac{1-\gamma^N}{1-\gamma}$ ($\Gamma = N$ si $\gamma = 1$)

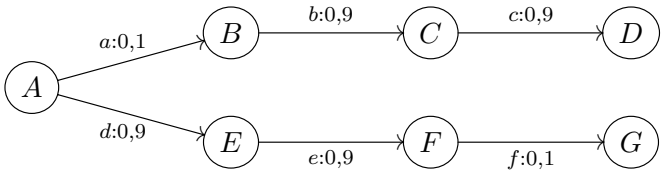
$$agg_{\gamma}(s_0, s_1, \ldots, s_{n-1}) = \frac{\sum_{i=0}^{N-1} \gamma^i s_i}{\Gamma} \tag{14}$$

Cet opérateur permet d'accorder une grande importance aux événements au début d'une trace puis de manière exponentiellement décroissante à ceux qui arrivent à un temps avancé. On peut facilement définir de manière symétrique l'agrégateur $agg_{\gamma\ late}$:

$$agg_{\gamma\ late}(s_0, s_1, \ldots, s_{n-1}) = \frac{\sum_{i=0}^{N-1} \gamma^{N-1-i} s_i}{\Gamma} \tag{15}$$

Ce dernier accorde plus d'importance aux scores en fin de trace qu'à ceux du début (voir figure 5). La valeur du paramètre γ possède un rôle essentiel pour cet opérateur et doit être fixée relativement à la longueur de la liste : plus la liste des scores est longue plus γ doit être proche de 1 et inversement, pour des courtes listes il est préférable de fixer γ à des valeurs proches de 0.

On peut utiliser l'opérateur gamma si l'on souhaite pénaliser des événements avec un faible score en début de trace. Par exemple, si l'on utilise une norme statistique, on souhaite exclure les chemins qui dès les premiers temps possèdent un événement statistiquement peu probable, même si tous les événements qui en découlent ont une forte possibilité de se produire.



(a) LTS

chemin	1 - moyenne	1 - agg_γ	1- $agg_{\gamma late}$
ABCD	**0.3**	0.42	**0.21**
AEFG	**0.3**	**0.21**	0.42

(b) Coûts ($\gamma = 0.7$)

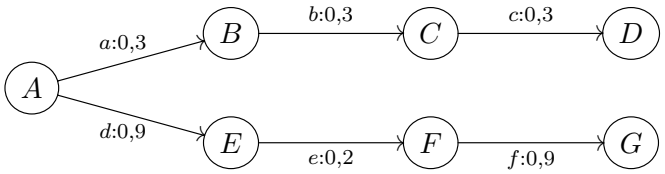
FIGURE 5 – Prise en compte de la position temporelle avec les opérateurs gamma

Les opérateurs gamma permettent de prendre en compte le temps dans l'agrégation des scores, ils ne sont pas invariants à la longueur de la trace et ne permettent pas une réelle compensation entre des scores s'ils sont éloignés temporellement. Une étude de l'influence du paramètre γ sur les résultats se trouve en annexe C.5.

Opérateur seuil Soit $\eta \in [0, 1]$:

$$agg_{seuil}(s_0, \ldots, s_{n-1}) = \begin{cases} 0 & si \quad \exists i < n \ tel \ que \ s_i < \eta \\ 1 & sinon \end{cases} \tag{16}$$

L'opérateur de seuil permet soit de pénaliser complètement un contrefactuel si un événement possède un score inférieur au seuil fixé soit de ne pas pénaliser si un tel événement n'apparaît pas dans la trace, voir figure 6.



(a) LTS

chemin	1 - moyenne	1 - agg_{seuil}
ABCD	0.6	**0**
AEFG	**0.33**	1

(b) Coûts ($\eta = 0.25$)

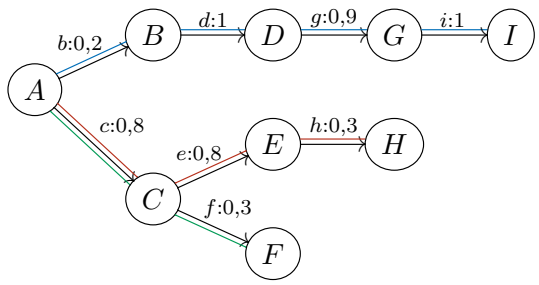
FIGURE 6 – Application opérateur de seuil

Cet opérateur peut présenter un intérêt dans des cas critiques où l'on se refuse de passer sous un seuil de score de normativité quel que soit le reste des événements.

4.3.4 Sélection des événements à évaluer

Pour le moment, nous avons agrégé l'ensemble des scores d'un chemin causal. Cependant, comme le travail porte in fine sur une évaluation de contrefactuels, on peut vouloir se concentrer uniquement sur les transitions pour lesquelles une alternative existe, c'est-à-dire les états avec strictement plus d'une transition sortante.

Comme on l'observe sur la figure 7, considérer seulement les événements avec une alternative modifie complètement les résultats. On évalue la qualité des choix pris durant un scénario et non plus le scénario dans sa globalité. Lorsque l'on évalue la normativité totale, c'est le chemin bleu qui minimise le coût. Or ce scénario, pour l'unique choix possible qu'il a, a effectué le pire choix. Contrairement à ce dernier, le chemin rouge sur les deux événements qui présentent une alternative prend les événements qui maximisent le score. En réduisant les événements à considérer c'est le chemin rouge qui minimise le coût.



(a) LTS

chemin	1 - agg_{geo}	événements comptés
bleu	0.**35**	b, d, g, i
rouge	0.42	c, e, h
vert	0.51	c, f

(b) Coûts globaux ($\gamma = 0.7$)

chemin	1 - agg_{geo}	événements comptés
bleu	0.8	b
rouge	**0.2**	c, e
vert	0.51	c, f

(c) Coûts sur les choix ($\gamma = 0.7$)

FIGURE 7 – Impact du choix des événements pour l'évaluation

4.4 Acceptabilité des contrefactuels : filtres a posteriori

La fonction de coût proposée permet d'évaluer la qualité des contextes causaux contrefactuels, et ainsi de les ordonner. Dans notre formalisme tout contexte causal différent de l'observation est un contrefactuel. On peut souhaiter affiner cette définition en introduisant des filtres a posteriori. Ils permettent d'établir une forme d'acceptabilité des contrefactuels. Le premier filtre introduit une notion de validité au sens XAI en imposant que l'état terminal de la trace du contrefactuel diffère de celui de l'observation. Le second prend la forme de bornes d'acceptabilité, en ne considérant comme acceptable que les contextes dont le coût est inférieur à seuil.

Soit $\chi = (\pi, S_0, \tau)$ le contexte causal observé avec $\sigma^{\chi}_{|state} = [S^{\chi}(0), \ldots, S^{\chi}(n)]$ et $\chi' = (\pi', S'_0, \tau)$ le contexte causal contrefactuel que l'on évalue, avec $\sigma^{\chi'}_{|state} = [S^{\chi'}(0), \ldots, S^{\chi'}(m)]$ et $\delta \in \mathbb{R}^+$, χ' est valide si :

$$S^{\chi}(n) \neq S^{\chi'}(m) \quad \text{et} \quad Coût_{\tau}(\chi, \chi') < \delta. \tag{17}$$

On peut aussi envisager d'affiner le critère de validité en rajoutant des seuils propres à v et d_obs.

5 Transition d'un framework RAC vers LTS : PDDL

Les LTS ne constituent pas directement un langage pour le domaine du RAC, mais comme dit par SARMIENTO (2025), leur utilisation permet d'unifier des raisonnements dans différents cadres ainsi que de lever certaines ambiguïtés. Tout formalisme pouvant être représenté sous forme de LTS bénéficie ainsi des réflexions et observations de ce travail. Pour illustrer la possibilité de transition, nous allons développer la traduction d'un problème PDDL vers un LTS. La représentation LTS permet de travailler sur la comparaison de contextes causaux contrefactuels, mais on laisse le travail de recherche et de résolution de problèmes de planification aux outils préexistants. En effet, la complexité exponentielle d'un LTS en fonction du nombre d'états et d'actions n'est pas adaptée à la recherche de politique. En annexe E, se trouvent les preuves formelles des propriétés de représentabilité, de correction et de terminaison du parseur proposé.

5.1 Rappel sur PDDL

Un problème de planification est décrit en PDDL par deux types de fichiers. Le premier définit le domaine de planification, et contient la déclaration des types, des actions (effets et préconditions) ainsi que les axiomes et les règles du domaine. Le second fichier définit le problème, et indique les objets, les constantes spécifiques ainsi que la situation de départ et l'objectif. Un exemple se trouve en annexe F

5.2 Construction d'un LTS à partir d'un problème PDDL

Pour construire un LTS à partir d'un couple de fichiers (domaine, problème), on commence par instancier toutes les actions possibles à partir de leurs définitions et des objets du problème. Ce processus est explicité ci-dessous :

```
def instantiate(actions, objects):
    instanciated = []
    for action in actions:
        params = action.parameters
        for args in product(objects, repeat=len(params)):
            val = dict(zip(params, args))
            name, precond,effect =  action.apply(val)
            instanciated.append((name, precond, effect))
    return instanciated
```

Une fois l'ensemble de toutes les actions instanciées et avant de pouvoir construire le LTS, on définit la fonction de satisfaction de préconditions. Pour un ensemble de préconditions et un état représenté par un ensemble de fluents, cette fonction vérifie si les préconditions sont respectées dans l'état. Cette fonction supporte les préconditions négatives, disjonctives et conjonctives.

```
def statisfied(preconditions,state):
    if preconditions conjonctives:
        return all(satisfied(p,state) for p in preconditions)
    if preconditions negatives:
        return not satisfied(preconditions,state)
    if preconditions disjonctives:
        return any(satisfied(p,state) for p in preconditions)
    return precondition in state
```

La seconde fonction qui est nécessaire avant celle de construction du graphe est la fonction d'application des effets positifs et négatifs d'une action dans un état.

```
def apply_effects(effects,state):
    new_state = state
    for f in effects:
        if isinstance(f, Not):
            new_state.discard(f) # effet negatif
        else:
            new_state.add(f) #effet positif
    return new_state
```

Avec ces trois fonctions, on peut maintenant définir la fonction de construction du LTS associé au problème PDDL. Un état est défini par l'ensemble des prédicats qui sont vrais dans ce dernier. On utilise une pile pour progresser dans la construction du graphe. À chaque nouvel état, on observe parmi toutes les actions possibles celles qui sont applicables en fonction de leurs préconditions. Si une action est applicable, on ajoute une nouvelle arête qui a pour état d'arrivée soit un état préexistant soit un nouvel état que l'on ajoute à la pile. Les états finaux sont les états dans lesquels les conditions de l'objectif sont respectées. Pour les distinguer des autres états, une arête réflexive est ajoutée.

```
def build_graph(actions, init_state, goals):
    state = init_state
    G = graph
    G.add_node(state)
    queue = [state]
    visited = {}
    while queue:
        current_node = queue.pop(0)
        if current_node in visited:
            continue
```

```
        visited.add(current_node)

        for preconditions, effects in actions:
            if satisfied(preconditions, current_node):
                new_node = apply_effect(effects, current_node)

            exist = new_node in G.nodes
            if not exist:
                G.add_node(new_node)
            else:
                continue

            G.add_edge(current_node, new_node)

            if new_node not in visited:
                queue.append(new_node)

    for node in G.nodes:
        if satisfied(goals, node):
            G.add_edge(node,node, action = '$\\varnothing')
```

5.3 Remarques et limites

Il est possible de continuer de tirer parti de PDDL et de ses solveurs pour extraire de manière automatique des politiques qui nous permettent par la suite de travailler sur des contextes causaux. Pour construire la politique, on avance dans le graphe depuis l'état de départ en attribuant à chaque état dans lequel on se trouve l'action associée dans le plan. Si besoin, ces politiques partielles peuvent ensuite être complétées aléatoirement ou selon une heuristique.

Il est à noter que les LTS correspondent à une sémantique et non pas à des outils manipulables en pratique. Leur utilité pour des applications concrètes reste limitée et ils seront surtout utilisés de manière formelle pour raisonner. Pour des applications à des exemples simples, ils permettent une meilleure visualisation, et on considère donc suffisant un parseur simple comme présenté ci-dessus. L'idée de cette section étant principalement d'expliciter la faisabilité d'une transition d'un cadre de RAC vers des LTS, de possibles améliorations sont laissées en suspend, car ne représentant pas l'objet principal du travail. Nous laissons son optimisation pour des travaux futurs. On peut par exemple noter que ce parseur ne traite que des problèmes PDDL contenant uniquement les extensions STRIPS, préconditions disjonctives et préconditions négatives. Le choix de s'appuyer sur PDDL dans ce travail se justifie aussi par le nombre d'instances de problèmes déjà disponibles en PDDL, ce qui en fait un support pratique pour la génération d'exemples.

5.4 Exemple de problème PDDL

Nous appliquons dans cette section notre parseur sur une instanciation de problème PDDL issu de `https://github.com/arii/planning_exercises/tree/master`. Le domaine correspond à un domaine Block World classique avec les quatre actions classiques de manipulation d'objets (*"pick-up"*, *"put-down"*, *"stack"*,*"unstack"*). La définition complète du domaine se trouve dans l'annexe F.1. Le problème contient deux objets bloc A et bloc B, initialement le bras ne tient rien, le bloc B est posé sur la table et le bloc A au-dessus de B. L'objectif est de poser A sur la table et que rien ne soit posé sur B. Les conditions de l'objectif sont donc respectées dans deux états : A est posé sur la table et B est posé sur la table, ou bien A est posé sur la table et B est posé sur A.

Définition du domaine

Voir annexe F.1

Définition du problème

Lié au domaine défini dans l'annexe F.1, on introduit une définition de problème. Initialement A et B sont sur la table et on cherche à atteindre un état où B se trouve sur A :

```
(define (problem bw-simple)
  (:domain bw)
  (:objects a b )
  (:init (clear a) (arm-empty) (on a b) (on-table b))
  (:goal (and (on-table a) (clear b))))
```

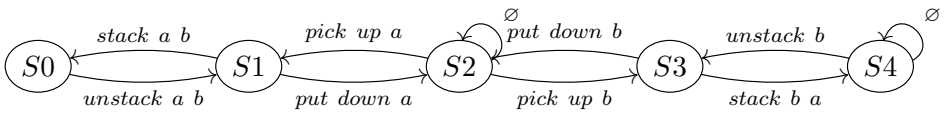


FIGURE 8 – LTS obtenu pour le problème simple de block world. Avec S0 ={'clear a', 'on a b', 'on table b', 'arm-empty'}, S1 ={'on table b', 'clear b', 'holding a'}, S2 ={'on table b','arm empty", 'clear b','clear a', 'on table a'}, S3 ={'holding b','on table a', 'clear a'}, S4 ={'on b a', 'on table a', 'arm empty', 'clear b'}

6 Application : exemple du poison

Dans cette partie, nous allons présenter un exemple concret d'application du travail introduit précédemment. Cette section est organisée sous forme de pipeline : nous partons d'un problème défini en PDDL que nous convertissons en LTS, nous ajoutons une évaluation experte avant d'appliquer différentes configurations de la fonction de coût pour en analyser les nuances. L'exemple défini correspond à une situation dans laquelle se trouve un verre qui contient à l'origine de l'eau. On considère que différents événements peuvent se produire pour altérer la potabilité de ce dernier et entraîner ou non la mort de la personne qui le boit. Les événements sont évalués selon une norme que l'on laisse floue, mais qui correspond approximativement à une norme du bien dans le sens où un événement est jugé comme peu normal s'il est associé à une nuisance (comme empoisonner le verre qui peut entraîner la mort) et comme très normal s'il entraîne un bénéfice (verser un antidote dans un verre empoisonné permet de sauver une personne). Dans notre modélisation un verre vide entraîne la mort. Cela peut paraître contre-intuitif, mais cette modélisation s'inspire d'un exemple connu en causalité. Cet exemple représente un voyageur dans le désert qui se fait empoisonner sa gourde avant qu'un second ne la lui vide. Nous nous inspirons de cet exemple pour représenter la possibilité de mourir de soif et évaluons subjectivement l'action de vider un verre comme moins mauvaise que de l'empoisonner. La modélisation de la situation et de l'évaluation est entièrement subjective et pourrait être complexifiée, mais nous souhaitons garder un exemple simple pour plus de lisibilité.

6.1 De PDDL vers un LTS

La définition des fichiers PDDL se trouve en annexe F.2. Ci-dessous est présenté le LTS résultant de l'application du parseur.

$$
\begin{aligned}
\mathbb{F} &= \{VerreOK(VO), VerreEmpoisonné(VE), VerreVide(VV), \\
&\quad VerreAntidote(VA), Mort, Vivant\} \\
\mathbb{E} &= \{empoisonner, antidote, boire_{VO}, boire_{VA}, boire_{VE}, vider_{VO}, vider_{VE}\} \\
\mathbb{A} &= \{Vivant, Mort\} \\
\mathbb{T} &= \mathbb{N} \\
&\quad pre(boire_{VO}) = VO \quad pre(antidote) = VE \\
&\quad pre(boire_{VA}) = VA \quad pre(boire_{VE}) = VE \\
&\quad pre(empoisonner) = VO \quad pre(vider_{VO}) = VO \\
&\quad pre(vider_{VE}) = VE \\
&\quad pre(\emptyset) = VV \vee Mort \vee Vivant
\end{aligned}
$$

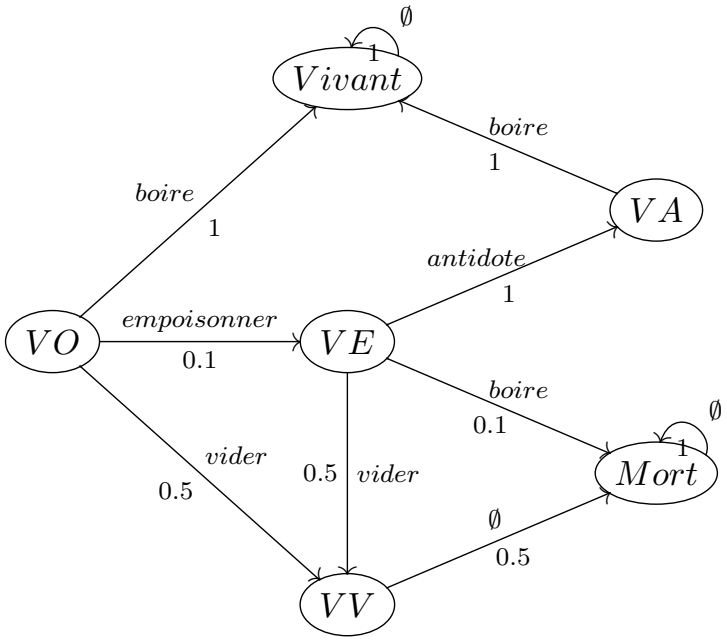
Un état du système doit décrire de façon complète et sans ambiguïtés une situation, il faut donc préciser la valeur de chacun des fluents. Par souci de lisibilité, chaque état dans notre modélisation est désigné par l'unique fluent qui y est vrai.

$$
\mathbb{S} = \left\{ \begin{array}{r}
VO = VO \wedge \neg VE \wedge \neg VV \wedge \neg VA \wedge \neg \text{Mort} \wedge \neg \text{Vivant}, \\
VE = \neg VO \wedge VE \wedge \neg VV \wedge \neg VA \wedge \neg \text{Mort} \wedge \neg \text{Vivant}, \\
VV = \neg VO \wedge \neg VE \wedge VV \wedge \neg VA \wedge \neg \text{Mort} \wedge \neg \text{Vivant}, \\
VA = \neg VO \wedge \neg VE \wedge \neg VV \wedge VA \wedge \neg \text{Mort} \wedge \neg \text{Vivant}, \\
\text{Mort} = \neg VO \wedge \neg VE \wedge \neg VV \wedge \neg VA \wedge \text{Mort} \wedge \neg \text{Vivant}, \\
\text{Vivant} = \neg VO \wedge \neg VE \wedge \neg VV \wedge \neg VA \wedge \neg \text{Mort} \wedge \text{Vivant}
\end{array} \right\}
$$

Pour alléger la notation, on fusionne la notation de $boire_{VO}, boire_{VA}, boire_{VE}$ en $boire$ et de $vider_{VO}, vider_{VE}$ en $vider$.

$$
\tau = \left\{ \begin{array}{r}
(VE, vider, VV), (VE, boire, Mort), (VE, antidote, VA), (Mort, \emptyset, Mort) \\
(VV, \emptyset, Mort), (VA, boire, Vivant), (Vivant, \emptyset, Vivant), (VO, boire, vivant), \\
(VO, empoisonner, VE), (VO, vider, VV),
\end{array} \right\}
$$

$$
expert_judge_{\tau} = \left\{ \begin{array}{r}
VO : \{boire : 1,\ vider : 0.5,\ empoisonner : 0.1\}, \\
VE : \{antidote : 1,\ boire : 0.1,\ vider : 0.5\}, \\
VV : \{\emptyset : 0.5\}, \\
VA : \{boire : 1\}, \\
\text{Mort} : \{\emptyset : 1\}, \\
\text{Vivant} : \{\emptyset : 1\}
\end{array} \right\}
$$



(18)

6.2 Définition des contextes causaux

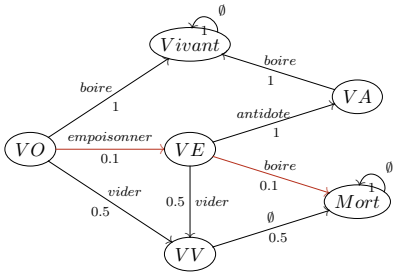
On réduit le champ de travail en ne travaillant que sur des contextes causaux partageant le même état de départ $S_0 = VO$ et une politique correcte relativement au LTS $< \$, \tau >$.

- Contexte causal $\chi_1 = (\pi_1, S_0, \tau)$ avec $\pi_1 \in \Pi_\tau$:

  $\pi_1(VO) = \{empoisonner\}, \quad \pi_1(VE) = \{boire\}, \quad \pi_1(mort) = \{\emptyset\}$
  $\pi_1(VV) = \{\emptyset\}, \quad \pi_1(VA) = \{boire\}, \quad \pi_1(vivant) = \{\emptyset\}$

  On obtient :

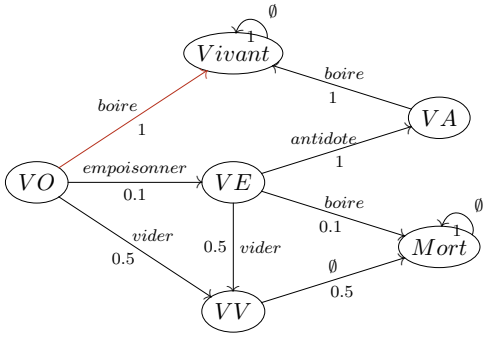
  — $\sigma^{\chi_1} = [VO, empoisonner, VE, boire, Mort]$
  — $\sigma^{\chi_1}_{|state} = [VO, VE, Mort]$
  — $\sigma^{\chi_1}_{|event} = [empoisonner, boire]$



- Contexte causal $\chi_2 = (\pi_2, S_0, \tau)$avec $\pi_2 \in \Pi_\tau$:

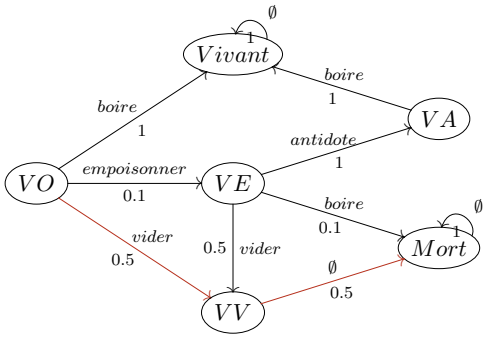
  $\pi_2(VO) = \{boire\}, \quad \pi_2(VE) = \{boire\}, \quad \pi_2(mort) = \{\emptyset\}$
  $\pi_2(VV) = \{\emptyset\}, \quad \pi_2(VA) = \{boire\}, \quad \pi_2(vivant) = \{\emptyset\}$

  — $\sigma^{\chi_2} = [VO, boire, Vivant]$
  — $\sigma^{\chi_2}_{|state} = [VO, Vivant]$
  — $\sigma^{\chi_2}_{|event} = [boire]$



- Contexte causal $\chi_3 = (\pi_3, S_0, \tau)$ avec $\pi_3 \in \Pi_\tau$:

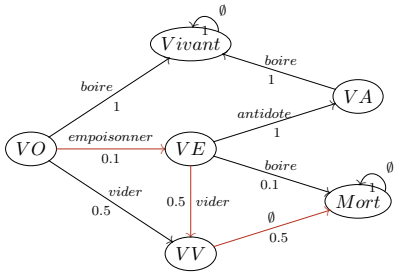
$\pi_3(VO) = \{vider\}, \quad \pi_3(VE) = \{boire\}, \quad \pi_3(mort) = \{\emptyset\}$
$\pi_3(VV) = \{\emptyset\}, \quad \pi_3(VA) = \{boire\}, \quad \pi_3(vivant) = \{\emptyset\}$



- $\sigma^{\chi_3} = [VO, vider, VV, \emptyset, Mort]$
- $\sigma^{\chi_3}_{|state} = [VO, VV, Mort]$
- $\sigma^{\chi_3}_{|event} = [vider, \emptyset]$

- Contexte causal $\chi_4 = (\pi_4, S_0, \tau)$ avec $\pi_4 \in \Pi_\tau$:

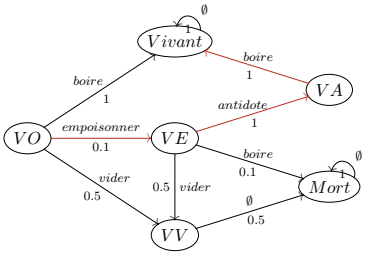
$\pi_4(VO) = \{empoisonner\}, \quad \pi_4(VE) = \{vider\}, \quad \pi_4(mort) = \{\emptyset\}$
$\pi_4(VV) = \{\emptyset\}, \quad \pi_4(VA) = \{boire\}, \quad \pi_4(vivant) = \{\emptyset\}$



- $\sigma^{\chi_4} = [VO, empoisonner, VE, vider, VV, \emptyset, Mort]$
- $\sigma^{\chi_4}_{|state} = [VO, VE, VV, Mort]$
- $\sigma^{\chi_4}_{|event} = [empoisonner, vider, \emptyset]$

- Contexte causal $\chi_5 = (\pi_5, S_0, \tau)$ avec $\pi_5 \in \Pi_\tau$:

$\pi_5(VO) = \{empoisonner\}, \quad \pi_5(VE) = \{antidote\}, \quad \pi_5(mort) = \{\emptyset\}$
$\pi_5(VV) = \{\emptyset\}, \quad \pi_5(VA) = \{boire\}, \quad \pi_5(vivant) = \{\emptyset\}$



- $\sigma^{\chi_5} = [VO, empoisonner, VE, antidote, VA, boire, Vivant]$
- $\sigma^{\chi_5}_{|state} = [VO, VE, VA, Vivant]$
- $\sigma^{\chi_5}_{|event} = [empoisonner, antidote, boire]$

6.3 Définition des politiques optimales

On définit les politiques optimales, avec et sans planification (présentées dans la section 4.3.2), associées au LTS :

Politique optimale sans planification :

$$\pi_\tau^{opt1}(VO) = \{boire\}, \quad \pi_\tau^{opt1}(VE) = \{antidote\}, \quad \pi_\tau^{opt1}(VV) = \{\emptyset\}, \quad \pi_\tau^{opt1}(Mort) = \{\emptyset\}$$
$$\pi_\tau^{opt1}(VA) = \{boire\}, \quad \pi_\tau^{opt1}(Vivant) = \{\emptyset\}$$

Politique optimale avec planification :

$$\pi_\tau^{opt2}(VO) = \{boire\}, \quad \pi_\tau^{opt2}(VE) = \{antidote\}, \quad \pi_\tau^{opt2}(VV) = \{\emptyset\}, \quad \pi_\tau^{opt2}(Mort) = \{\emptyset\} \quad (19)$$
$$\pi_\tau^{opt2}(VA) = \{boire\}, \quad \pi_\tau^{opt2}(Vivant) = \{\emptyset\} \quad (20)$$

On note $\forall S \in \$, \quad \pi_\tau^{opt1}(S) = \pi_\tau^{opt2}(S)$. On notera par la suite simplement π_τ^{opt}.

6.4 Résultats

En fonction de la configuration choisie (extraction d'une politique optimale, exploitation directe, évaluation de la normalité globale, sur les événements avec alternatives uniquement) et des hyper

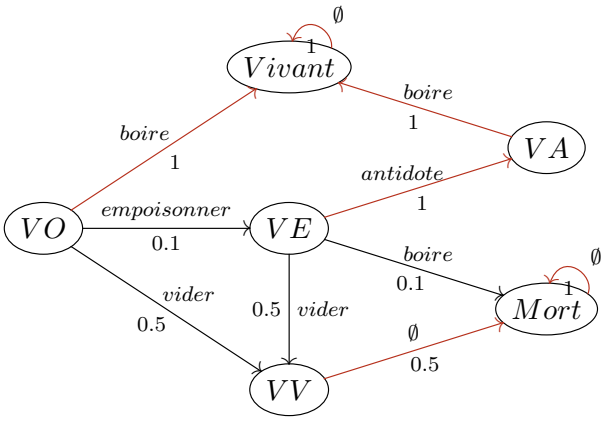


FIGURE 9 – Politique optimale : les flèches rouges indiquent dans chaque état l'événement choisi par la politique optimale.

paramètres $(\lambda_1, \lambda_2, \gamma...)$ on obtient différents résultats. Une connaissance a priori des contraintes que l'on souhaite appliquer lors de l'évaluation permet de guider le classement.

Dans les exemples suivants, on considère, si ce n'est pas précisé, que le contexte causal observé est χ_1. On fixe $\lambda_1 = \lambda_2 = 1$ et un coût maximal $\delta = 2$. Avec cette valeur, la validité ne dépend que de la différence entre les deux états finaux des traces de l'observation et du contrefactuel.

Priorité à des contrefactuels avec des scores d'événements stables : On choisit pour la fonction de vraisemblance la formule 12 avec l'opérateur d'agrégation agg_{geo} et on agrège les scores de tous les événements des scénarios. On souhaite dans cette configuration pénaliser des traces avec une variance de score importante. Les résultats sont donnés en résumé dans la table 1

CF	classement	d_{obs}	v	$d_{\text{obs}} + v$	trace	valide
1	χ_2	0.67	0.0	0.67	$[VO, boire, Vivant]$	✓
3	χ_3	0.33	0.5	0.83	$[VO, vider, VV, \emptyset, Mort]$	×
4	χ_4	0.25	0.71	0.96	$[VO, empoisonner, VE, vider, VV, \emptyset, Mort]$	×
2	χ_5	0.50	0.54	1.04	$[VO, empoisonner, VE, antidote, VA, boire, Vivant]$	✓

TABLE 1 – Résultats pour la priorité à la normativité.

D'après la table 1, le contrefactuel avec le coût minimal est χ_2 (distance de 0.67, vraisemblance nulle car l'unique événement *boire* a un score de 1). Il est valide : son état final ($Vivant$) diffère de l'observation ($Mort$). χ_3 et χ_4, bien que moins coûteux que χ_5, ne le sont pas, leur état final étant $Mort$. Entre les deux contrefactuels valides, χ_2 est favorisé par rapport à χ_5 grâce à des scores plus stables et plus élevés, χ_5 étant pénalisé par l'événement *empoisonner*. Ce résultat confirme le comportement attendu de la configuration, qui privilégie les traces avec une faible variance dans les scores.

Interdiction de dépasser un seuil On utilise l'opérateur d'agrégation avec un seuil fixé à $\eta = 0.2$ pour pénaliser les contrefactuels dont le scénario contient un empoisonnement. On fixe aussi un coût maximal de 0.5 pour le coût de vraisemblance. Les résultats sont synthétisés dans la table 2

Dans cette configuration, le contexte causal χ_2 est le seul contexte valide. En ajoutant une contrainte sur le coût de vraisemblance, on exclut automatiquement les contrefactuels qui possèdent un événement inférieur au seuil, ici l'événement *empoisonner*. Cela impacte la validité des contrefac-

CF	classement	d_{obs}	v	$d_{\text{obs}} + v$	trace	valide
2	χ_2	0.67	0.0	0.67	$[VO, boire, Vivant]$	✓
1	χ_3	0.33	0.0	0.33	$[VO, vider, VV, \emptyset, Mort]$	×
3	χ_4	0.25	1.0	1.25	$[VO, empoisonner, VE, vider, VV, \emptyset, Mort]$	×
4	χ_5	0.50	1.0	1.50	$[VO, empoisonner, VE, antidote, VA, boire, Vivant]$	×

TABLE 2 – Résultats pour l'interdiction de dépasser un seuil.

tuels, en effet, χ_5 a un état final différent de l'observation, mais il dépasse les bornes d'acceptabilité fixées.

Normativité en début de scénario On utilise maintenant l'opérateur agg_γ, avec $\gamma = 0.25$, qui avantage les scénarios qui ont des scores élevés sur les événements en début de trace et en considérant peu ceux en fin de trace (table 3).

CF	classement	d_{obs}	v	$d_{\text{obs}} + v$	trace	valide
1	χ_2	0.67	0.0	0.67	$[VO, boire, Vivant]$	✓
2	χ_3	0.33	0.5	0.83	$[VO, vider, VV, \emptyset, Mort]$	×
3	χ_4	0.25	0.80	1.05	$[VO, empoisonner, VE, vider, VV, \emptyset, Mort]$	×
4	χ_5	0.50	0.69	1.19	$[VO, empoisonner, VE, antidote, VA, boire, Vivant]$	✓

TABLE 3 – Priorité à la normativité en début de scénario.

On observe avec la table 3 que le contrefactuel avec le plus faible coût correspond à χ_2 qui a le premier événement avec un score le plus élevé ($boire$ =1) suivit de χ_3 qui a un score pour son premier événement de 0.5. Les deux derniers contextes causaux possèdent en premier événement *empoisonner* ce qui vient fortement augmenter le coût. Les contextes causaux valides sont χ_2 et χ_5, ils restent les deux seuls contrefactuels avec un état final différent de l'observation.

Normativité en fin de scénario On utilise l'opérateur $gamma_{late}$ avec $\gamma = 0.25$. On priorise la normativité en fin de trace, couplée au coût sur la distance à l'observation. Ainsi, on cherche des contrefactuels qui ne diffèrent de l'observation qu'en fin de trace, mais qui restent le plus proche possible au début.

CF	classement	d_{obs}	v	$d_{\text{obs}} + v$	trace	valide
2	χ_2	0.67	0.0	0.67	$[VO, boire, Vivant]$	✓
4	χ_3	0.33	0.5	0.83	$[VO, vider, VV, \emptyset, Mort]$	×
3	χ_4	0.25	0.52	0.77	$[VO, empoisonner, VE, vider, VV, \emptyset, Mort]$	×
1	χ_5	0.50	0.04	0.54	$[VO, empoisonner, VE, antidote, VA, boire, Vivant]$	✓

TABLE 4 – Priorité à la normativité en fin de scénario.

La table des résultats 4 montre que, dans cette configuration, c'est χ_5 qui a le coût le plus faible, malgré l'empoisonnement, on s'éloigne de l'observation le plus tard possible.

Normativité du contrefactuel avec distance à une politique optimale On choisit pour cette configuration de calculer la distance à la politique optimale, définie dans la section 6.3. Le choix est fait de ne considérer que les événements pour lesquels une alternative existe.

Les résultats présentés dans la table 5 indiquent qu'avec cette configuration, le contexte causal avec le plus faible coût est le contexte χ_2 suivi de χ_5, les deux contrefactuels valides. Concernant la fonction de vraisemblance, dans la trace associée à χ_2 un seul événement est présent et un choix

CF	classement	d_{obs}	v	$d_{\text{obs}} + v$	trace	valide
1	χ_2	0.67	0.0	0.67	$[VO, boire, Vivant]$	✓
4	χ_3	0.33	1.0	1.33	$[VO, vider, VV, \emptyset, Mort]$	×
3	χ_4	0.25	1.0	1.25	$[VO, empoisonner, VE, vider, VV, \emptyset, Mort]$	×
2	χ_5	0.50	0.5	1.0	$[VO, empoisonner, VE, antidote, VA, boire, Vivant]$	✓

TABLE 5 – Résultats selon la distance à la politique optimale.

est possible. Le choix fait est l'événement *boire* qui correspond à l'événement choisi par la politique optimale donc le coût associé est de 0. Pour χ_5, deux événements avec alternative sont présents dans la trace *empoisonner* qui n'est pas l'événement choisi par la politique optimale, et *antidote* qui est similaire à la politique optimale. Sur les deux événements un seul est égal à la politique optimale donc un coût de 0.5 est appliqué. Pour χ_3 et χ_4 tous les choix possibles sont différents de la politique optimale, un coût de 1 leur est attribué.

Bilan

Ces différentes configurations et leurs résultats montrent la modularité et la pertinence de la mesure de qualité proposée. En fonction des priorités que l'on souhaite donner à l'évaluation (stabilité normative, pénalisation en début ou fin de scénario, proximité à une politique optimale), le classement des contrefactuels varie et reste cohérent avec l'intuition qui motive le choix de configuration. Cet exemple met en évidence l'importance du choix des composantes et des hyperparamètres dans l'évaluation d'un contrefactuel et confirme la capacité du cadre proposé à s'adapter à différentes exigences applicatives.

7 Conclusion

Ce stage avait pour objectif d'évaluer la qualité de contextes causaux contrefactuels dans le cadre des Systèmes de Transitions d'États Étiquetés, en tenant compte des normes. Une réflexion a notamment été menée sur la façon de représenter ces normes au sein de ce formalisme : le choix s'est porté sur une pondération des transitions du LTS. Ce travail répond à cet objectif au travers de deux contributions principales.

La première est une mesure d'évaluation constituée d'une fonction d'attribution de coût modulaire couplée à des filtres a posteriori définissant une forme d'acceptabilité des contrefactuels. La fonction de coût combine une mesure de distance à l'observation basée sur la distance de Levenshtein enrichie par la notion de mutabilité et une mesure de vraisemblance normative. Cette vraisemblance peut être calculée par comparaison à des politiques optimales ou par agrégation des pondérations le long d'une trace. Ce type de mesure, intégrant des normes sur des objets aussi riche que les LTS, qui distinguent explicitement états et événements et permettent de représenter des chaînes causales complexes, n'existait pas dans la littérature. La modularité de la fonction proposée est un atout important et permet d'adapter finement son usage en fonction de l'application : choix des opérateurs d'agrégation, des pondérations ou filtres a posteriori.

L'application à l'exemple du poison développée dans la section 6 illustre la pertinence de l'approche proposée : les différentes configurations testées produisent des classements de contrefactuels cohérents avec l'intuition attendue de chacun des critères. Cette approche a également été testée sur d'autres exemples, tels que l'exemple du jardinier, confirmant les résultats obtenus.

La seconde contribution est un parseur permettant de construire automatiquement un LTS à partir d'un problème PDDL, dont a été démontré formellement la correction, la terminaison ainsi que la représentabilité. Ce parseur nous a permis de générer des exemples classiques de la littérature pour valider notre approche.

Ce travail a nécessité d'articuler des concepts issus de plusieurs domaines de recherche tels que la causalité effective, l'explicabilité en IA et les sciences cognitives dans un même cadre formel. Cette démarche a mené à l'identification de divergences sémantiques se trouvant derrière des définitions propres à chaque domaine, comme, la notion d'acceptabilité. Elle a aussi permis d'intégrer la notion de mutabilité, issue des sciences cognitives à la définition de la distance à l'observation.

Le travail formel est accompagné d'une implémentation complète en Python, comprenant le cadre théorique (LTS, contextes causaux, fonction de coût modulaire et ses différentes composantes) ainsi que le processus d'évaluation incluant le parseur de PDDL vers LTS. Cette implémentation a permis de tester les différentes configurations de la fonction de coût sur des exemples, et constitue une base réutilisable pour de futurs travaux s'appuyant sur ce cadre.

Ce travail ouvre plusieurs perspectives. Sur le plan formel, le cadre pourrait être étendu à des transitions stochastiques, ce qui permettrait de mieux représenter la réalité, mais soulèverait en contrepartie des questions de stabilité et de robustesse des politiques face à l'incertitude, nécessitant l'ajout de nouveaux termes dans la fonction de coût pour en tenir compte. Une seconde piste serait d'intégrer un terme causal explicite, prenant en compte les fluents décrivant les états. On pourrait également envisager une évaluation floue des normes, plutôt qu'une pondération numérique stricte afin de mieux représenter le respect ou la violation de norme. Enfin, maintenant que nous avons défini une fonction de coût permettant d'évaluer la qualité de contextes causaux contrefactuels, il serait pertinent de nous intéresser à la construction automatique de contrefactuels visant à en minimiser la valeur.

A Exemple de contexte causal non valide pour la fonction de coût

Soit le LTS $\langle \$, \tau \rangle$, illustré figure 10, avec :

$$\$ = \{S_0, S_1, S_2, S_3\}$$
$$\tau = \{(S_0, a, S_1), (S_0, b, S_2), (S_2, c, S_3), (S_2, d, S_4), (S_1, \emptyset, S_1), (S_3, \emptyset, S_3), (S_4, \emptyset, S_4)\}$$

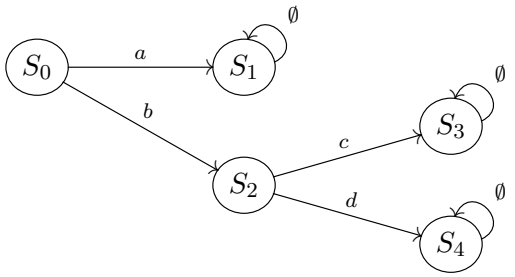


FIGURE 10 – Exemple de LTS.

On définit : $\chi_1 = (\pi_1, S_0, \tau)$, $(\chi_2 = \pi_2, S_3, \tau)$ $\chi_3 = (\pi_3, S_0, \tau)$ et avec :

$$\pi_1(S_0) = a \quad \pi_1(S_2) = c \quad et \quad \forall i \in [1,3,4], \pi_1(S_i) = \emptyset$$
$$\pi_2(S_0) = a \quad \pi_2(S_2) = d \quad et \quad \forall i \in [1,3,4], \pi_2(S_i) = \emptyset$$
$$\pi_3(S_0) = c \quad \pi_3(S_2) = d \quad et \quad \forall i \in [1,3,4], \pi_3(S_i) = \emptyset$$

A.1 Fonction *divergence*

$divergence(\chi_1, \chi_2) = +\infty$: même si ces deux contextes causaux sont différents le coût est de $+\infty$, les politiques divergent uniquement en S_2, or cet état est absent de $\sigma^{\chi_1} = [S_0, S_1]$. Les politiques sont égales sur la trace.

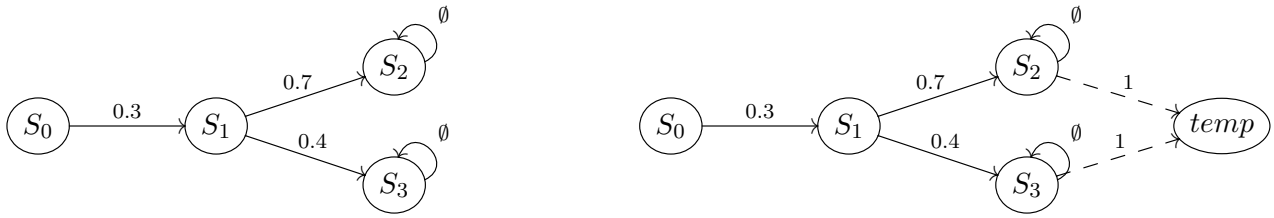
A.2 Fonction *correct*

$correct(\chi_3) = +\infty$ car la politique π_3 n'est pas correcte relativement au LTS :

$$\nexists S' \ tel \ que \ (S_0, c, S') \in \tau.$$

B Construction d'une politique optimale avec planification et l'utilisation de l'algorithme A*

Les algorithmes de plus court chemin nécessitent l'indication d'un état de départ et d'arrivée. Dans notre cas, on souhaite trouver le chemin qui minimise le coût sans contraindre à une destination fixe. Pour permettre cela, on crée un LTS temporaire, à partir de notre LTS de travail, auquel on ajoute un état "poubelle" (voir figure 11). On relie chaque état terminal du LTS original à ce nouvel état, et chaque transition entre un état terminal et l'état possède un score égal (par exemple 1). L'ajout de cet état nous permet d'appliquer un algorithme de recherche du plus court chemin en fixant l'état d'arrivée à l'état ajouté.



(a) LTS original

(b) LTS augmenté

FIGURE 11 – Construction du graphe pour l'application d'un algorithme de plus court chemin.

C Vérification des propriétés pour les opérateurs

Rappel : Définition et propriétés d'un opérateur d'agrégation : $Agg : \bigcup_{n\in\mathbb{N}} [0,1]^n \to [0,1]$

- identité si $n = 1$: $Agg(u) = u$
- conditions aux limites : $Agg(0,\dots,0) = 0$ et $Agg(1,\dots,1) = 1$
- monotonie croissante : $Agg(u_1,\dots,u,\dots,u_n) \leq Agg(u_1,\dots,v,\dots,u_n)$ si $u \leq v$

C.1 Opérateur géométrique

Soit $\varepsilon > 0$

$$agg_{geo}(s_0, s_1, \dots, s_{n-1}) = \exp\left(\frac{1}{N}\sum_{i<n} \log(\max(s_i, \varepsilon))\right) \tag{21}$$

Identité

$$agg_{geo}(u) = \exp(\log(\max(u,\varepsilon))) = \max(u,\varepsilon)$$

Si $u < \varepsilon$, $agg_{geo}(u) = \varepsilon \neq u$. La propriété d'identité n'est pas respectée.

Conditions aux limites

$$agg_{geo}(0,\dots,0) = \exp\left(\frac{1}{N}\sum_{i<n} \log(\varepsilon)\right) = \varepsilon \neq 0$$

$$agg_{geo}(1,\dots,1) = \exp\left(\frac{1}{N}\sum_{i<n} \log(1)\right) = 1$$

Pour la limite en zéro la condition n'est pas respectée.

Les propriétés d'identité et de conditions aux limites ne sont plus respectées après l'ajout de ε (contrairement à la moyenne géométrique classique). Cependant, nous considérons ces propriétés moins déterminantes pour notre application par rapport à l'avantage d'ajouter ε comme discuté dans la section 4.3.3.

Monotonie croissante Soit $u \leq v$, $Agg(u_1,\dots,u,\dots,u_n)$ ne diffère de $Agg(u_1,\dots,v,\dots,u_n)$ que par un seul terme de la somme. On veut montrer que $\log(\max(u,\varepsilon)) \leq \log(\max(v,\varepsilon))$, hors $\max(u,\varepsilon) \leq \max(v,\varepsilon)$ et donc par croissance du log, on obtient : $\log(\max(u,\varepsilon)) \leq \log(\max(v,\varepsilon))$. Donc la somme est plus petite et l'exponentielle aussi. La propriété de monotonie croissante est respectée.

C.2 Opérateur gamma

Soit $\gamma \in]0,1]$, $\Gamma = \frac{1-\gamma^N}{1-\gamma}$ ($\Gamma = N$ si $\gamma = 1$)

$$agg_\gamma(s_0, s_1, \ldots, s_{n-1}) = \frac{\sum_{i=0}^{N-1} \gamma^i s_i}{\Gamma} \tag{22}$$

Identité Soit $u \in [0,1]$, $N = 1$ donc $\Gamma = 1$

$$agg_\gamma(u) = \gamma^0 u = u$$

La propriété d'identité est donc respectée. L'identité étant vérifiée, on peut vérifier la propriété d'idempotence que l'on définit comme l'extension de l'identité avec un $n \geq 1$.

Soit $\mathbf{u} = (u, \ldots, u)$, $\mathbf{u} \in [0,1]^n$:

$$\begin{aligned} agg(u, \ldots, u) &= \frac{\sum_{i=0}^{N-1} \gamma^i u}{\Gamma} \\ &= u \frac{1-\gamma}{1-\gamma^N} \sum_{i=0}^{N-1} \gamma^i = u \frac{\sum_{i=0}^{N-1} \gamma^i - \gamma \sum_{i=0}^{N-1} \gamma^i}{1-\gamma^N} \\ &= u \frac{\sum_{i=0}^{N-1} \gamma^i - \sum_{i=0}^{N-1} \gamma^{i+1}}{1-\gamma^N} = u \frac{\sum_{i=0}^{N-1} \gamma^i - \gamma^{i+1}}{1-\gamma^N} \\ &= u \frac{1-\gamma^N}{1-\gamma^N} = u \end{aligned}$$

La propriété d'idempotence est bien vérifiée.

Conditions aux limites

$$agg_\gamma(0, \ldots, 0) = \frac{\sum_{i=0}^{N-1} \gamma^i 0}{\Gamma} = 0$$

$$agg_\gamma(1, \ldots, 1) = \frac{\sum_{i=0}^{N-1} \gamma^i 1}{\Gamma} = 1$$

Les conditions aux limites sont respectées.

Monotonie croissante Soit $u, v \in [0,1]$ tel que $u \leq v$

$$agg_\gamma(u_0, \ldots, u, \ldots, s_{n-1}) \leq agg_\gamma(u_0, \ldots, v, \ldots, s_{n-1}),$$

car $\gamma^i u \leq \gamma^i v$ La propriété de monotonie croissante est respectée.

C.3 Opérateur de seuil

Soit $\lambda \in]0,1]$

$$agg_{seuil}(s_0, \ldots, s_{n-1}) = \begin{cases} 0 & si \quad \exists i < n \ tel \ que \ s_i < \lambda \\ 1 & sinon \end{cases} \tag{23}$$

Identité Soit $u \in [0,1]$

$$agg_{seuil}(u) = \begin{cases} 0 & si \quad \exists i < n \ tel \ que \ u < \lambda \\ 1 & sinon \end{cases}$$

Si $u \neq 0$ ou $u \neq 1$ la propriété d'identité n'est pas respectée.

Conditions aux limites

$$agg_{seuil}(0, \ldots, 0) = 0 \quad agg_{seuil}(1, \ldots, 1) = 1$$

Les conditions aux limites sont respectées

Monotonie croissante Soit $u \leq v$, on veut montrer que :

$$agg_{seuil}(u_0, \ldots, u, \ldots, u_{n-1}) \leq agg_{seuil}(u_0, \ldots, v, \ldots, u_{n-1}).$$

- Si $agg_{seuil}(u_0, \ldots, v, \ldots, u_{n-1}) = 1$ on a :

$$agg_{seuil}(u_0, \ldots, u, \ldots, u_{n-1}) \leq agg_{seuil}(u_0, \ldots, v, \ldots, u_{n-1})$$

- Si $agg_{seuil}(u_0, \ldots, v, \ldots, u_{n-1}) = 0$ alors, il existe $i \in [0, n-1]$ tel que $u_i < \lambda$:
  — Si i est différent de l'indice de position de u et v, alors ce même u_i conduit aussi à :

$$agg_{seuil}(u_0, \ldots, u, \ldots, u_{n-1}) = 0$$

  — Si i correspond à l'indice de position de u et v on a $u \leq v < \lambda$ et donc :

$$agg_{seuil}(u_0, \ldots, u, \ldots, u_{n-1}) = 0.$$

La propriété de monotonie croissante est respectée.

C.4 Synthèse des résultats

Opérateur	Identité	Conditions aux limites	Monotonie croissante
agg_{geo}	×	× (en 0) / ✓ (en 1)	✓
agg_{γ}	✓	✓	✓
agg_{seuil}	×	✓	✓

TABLE 6 – Synthèse des propriétés des opérateurs d'agrégation.

C.5 Sensibilité de l'opérateur gamma au paramètre γ

La variable γ des opérateurs temporels influe directement sur le coût de vraisemblance d'un contexte contrefactuel. On peut noter quelques spécificités de cet opérateur : lorsque la trace contient un seul événement, γ n'a aucune influence et le score correspond à l'évaluation de l'événement. A contrario, plus le nombre d'événements est important plus la valeur de γ aura une influence. Si elle est fixée à 1, on effectue une simple moyenne arithmétique, plus on le fait tendre vers 0, plus l'opérateur ignore les résultats en début (opérateur agg_{γ_late}) ou fin de scénario (opérateur agg_{γ}).

Dans la figure 12, on observe l'évolution du coût de vraisemblance pour l'exemple du poison de la section 6. L'opérateur utilisé est agg_{γ} qui donne plus d'importance aux événements en début

de scénario. Le coût est calculé sur l'ensemble des événements des traces, relativement au contexte causal χ_1.

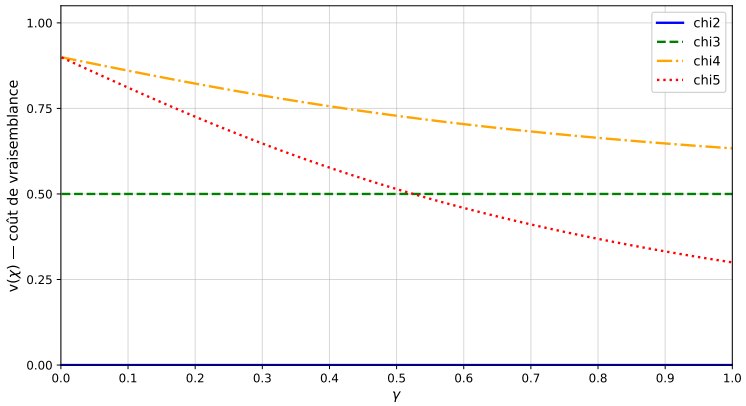


FIGURE 12 – Sensibilité au paramètre γ (agg_γ early)
Contexte observé : χ_1, $\lambda_2 = 1$

On observe sur la figure 12, l'impact de γ sur le coût de vraisemblance. Le contexte causal χ_2 (*VO, boire, Vivant*) contient un unique événement donc sa vraisemblance ne dépend pas de la valeur de γ. Le contexte causal χ_3 (*V0,vider,VV,∅,Mort*) ne dépend pas non plus de γ alors qu'il contient plus d'un événement. Ce comportement est dû aux scores des événements qui valent tous 0.5 et le fait que l'opérateur respecte une propriété d'idempotence. Lorsque tous les scores à agréger sont égaux, γ n'influe pas sur le résultat. Concernant les contextes causaux χ_4 (*VO, emp, VE,vider,VV,∅,Mort*) et χ_5 (*VO,emp, VE,anti,VA,boire,Vivant*), ils sont impactés par γ. Lorsque γ est proche de zéro, on prend en compte presque uniquement le premier événement, égal dans les deux scénarios qui est *empoisonner*. Plus la valeur de γ augmente, plus on s'intéresse à ce qui se passe en fin de scénario. Dans χ_5 un antidote est versé, et donc le coût chute plus fortement que dans χ_4. Autour de la valeur $\gamma = 0.5$ on observe un chevauchement des courbes de χ_3 et χ_5. Le contexte causal χ_5 devient moins coûteux que χ_3. Cela montre l'importance de fixer correctement γ. Pour cela, il faut avoir en tête ces valeurs de bascule, même si elles ne sont pas automatiquement présentes, elles peuvent exister. Il est aussi important de fixer γ en fonction de la longueur des scénarios que l'on traite. Si les scénarios sont courts, on favorisera un γ relativement faible (≤ 0.5) et on l'augmentera pour des longueurs plus importantes.

D Digression sur le concept de sélection causale dans le domaine des sciences cognitives

De nombreuses recherches en sciences cognitives ont été menées pour tenter de modéliser la façon dont nous concevons et préférons certains scénarios contrefactuels par rapport à d'autres. Ces mécanismes sont influencés par différents critères tels que la structure causale, le temps, les normes, la valeur de l'effet produit... Même si certaines études portent, plus ou moins implicitement, sur la notion de responsabilité causale plus que sur le concept de sélection causale, des définitions et concepts peuvent être utiles pour définir et orienter les critères d'évaluation ou encore de construction de scénarios contrefactuels. Je présente ci-dessous une liste non exhaustive de notions trouvées dans la littérature pouvant être potentiellement intégrées à notre cadre.

D.1 Mutabilité et propensité des facteurs

Les notions de mutabilité (à quel point il est simple d'imaginer qu'un facteur ait pu être différent) et de propensité (la vraisemblance qu'un effet ait lieu sachant une cause) jouent, selon KOMINSKY

et al. (2015) et McGill et Tenbrunsel (2000), un rôle essentiel dans le raisonnement contrefactuel. Le premier article vise à mettre en évidence, dans le processus d'évaluation causale d'un événement A, l'importance de la mutabilité et de la propensité d'un événement B nécessaire à la production de l'effet (structure causale conjointe). D'autre part dans (Kominsky et al. 2015) le travail porte cette fois-ci sur le phénomène de *"causal superseding"* qui est décrit comme : le phénomène selon lequel la violation d'une norme par un agent diminue la causalité attribuée à un autre agent. Même si cet effet sort de notre cadre par son aspect multiagents, on trouve des résultats similaires à ceux de McGill et Tenbrunsel (2000). Ils avancent, eux aussi, que selon leur modèle, un facteur causal est vu comme plus faible lorsqu'un autre facteur est plus mutable, mais uniquement si ce facteur est très susceptible de produire l'effet. La mutabilité a été introduite dans la fonction d'évaluation proposée dans la section 4.

D.2 Impact des normes sur le raisonnement contrefactuel

Dans (Icard, Kominsky et Knobe 2017) une mesure de force de causalité (correspondant à un compromis entre suffisance et nécessité) est présentée et permet de modéliser les effets de la normalité sur le jugement causal. Dans ce travail aucune distinction entre les types de normes (statistique ou prescriptive) n'est appliquée et les auteurs travaillent dans un cadre non déterministe ne faisant pas de différence entre les états et les événements. Cette mesure n'est donc pas directement applicable à notre cadre, mais les effets discutés présentent des intérêts potentiels. Une différence des effets de la normalité est faite selon la structure causale. Dans les cas conjonctifs, on observe un effet d'*abnormal inflation* décrit par le fait qu'une cause est considérée comme plus causale si elle est anormale par rapport au cas où elle est normale. Le second effet pour les structures conjonctives est l'effet de *supersession* : un facteur est considéré comme plus causal lorsque les autres facteurs sont normaux. Dans le cas disjonctif, on observe l'effet d'*abnormal deflation* : une cause est considérée comme plus causale lorsque qu'elle est normale que lorsqu'elle ne l'est pas. Et enfin toujours dans le cas disjonctif l'effet de *no supersession with disjunction* qui avance qu'une cause est tout aussi encline à être jugée comme causale lorsqu'une seconde cause est normale, que lorsqu'elle est anormale.

D.3 Influence du temps sur le raisonnement contrefactuel

Dans (Henne et al. 2021), le travail porte sur l'influence qu'a la position temporelle d'un événement dans une séquence causale sur le jugement de sa responsabilité, et comment le raisonnement contrefactuel peut expliquer ces effets. Le premier effet discuté est l'effet de récence (dans un match, on juge plutôt le dernier but comme la cause de la victoire plutôt que le premier). Mais les auteurs observent que dans des cas de surdétermination et plus particulièrement de préemption tardive, cet effet s'inverse : si chaque effet est suffisant alors la causalité est attribuée à l'événement le plus ancien. Ils étendent le *necessity-sufficiency model* présenté par Icard, Kominsky et Knobe (2017), qui avance que plus un événement fait une différence dans une simulation contrefactuelle, plus il est vu comme causal, en introduisant l'hypothèse selon laquelle les gens sont plus enclins à imaginer des contrefactuels autour de l'événement le plus récent (quelle que soit la structure). Avec cette extension du modèle causal, le mécanisme est toujours le même (simuler le contrefactuel de l'événement le plus récent) mais c'est la structure causale qui détermine ce que la pensée contrefactuelle révèle. Dans un cas, elle indique que l'événement causal est le plus récent et dans l'autre c'est le plus ancien.

E Démonstrations des propriétés du parseur

On souhaite démontrer les propriétés de correction et de terminaison du parseur. Trois objets de statut différents interviennent dans les démonstrations :

- $\mathcal{P}$: le problème PDDL, qui est la donnée du problème.
- $\langle \mathbb{S}^*, \tau^* \rangle$: le LTS cible, défini à partir de $\mathcal{P}$. Il représente mathématiquement le LTS que l'on souhaite obtenir, indépendamment de tout algorithme.

- $T(\mathcal{P}) = \langle \mathbb{S}, \tau \rangle$: le LTS effectivement obtenu par notre parseur T en pratique, lorsqu'on lui donne $\mathcal{P}$ en entrée.

On introduit maintenant les notations formelles associées à ces objets :
Soit $\mathcal{P} = (\mathcal{O}, \mathcal{A}, Pred, S_{init}, \mathcal{G})$ un problème PDDL avec :

- $\mathcal{O}$: l'ensemble des objets du problème,
- $Pred$: l'ensemble des prédicats déclarés dans le domaine de $\mathcal{P}$,
- $\mathbb{F}(\mathcal{P}) = \{p(o_1, \ldots, o_k) \mid p \in Pred, (o_1, \ldots, o_k) \in \mathcal{O}^k\}$: ensemble des prédicats instanciables du domaine (ensemble fini, car $Pred$ et $\mathcal{O}$ sont finis),
- $\mathcal{A}$: l'ensemble des actions du problème. Pour tout $a \in \mathcal{A}$ on définit le tuple :

$$(param(a), pre(a), eff^+(a), eff^-(a))$$

  et $pre(a), eff^+(a), eff^-(a) \in 2^{\mathbb{F}(\mathcal{P})}$, avec $param(a)$ les paramètres de l'action a, $pre(a)$ ses préconditions, $eff^+(a)$ ses effets positifs et $eff^-(a)$ ses effets négatifs.
- $\mathbb{E}(\mathcal{P}) = \{a(o_1, \ldots, o_k) \mid a \in \mathcal{A}, (o_1, \ldots, o_k) \in \mathcal{O}^k, k = |param(a)|\}$: ensemble des actions instanciables à partir des objets du domaine,
- S_{init} : l'ensemble des vrais prédicats dans l'état initial (hypothèse de monde clos), $S_{init} \in 2^{\mathbb{F}(\mathcal{P})}$
- $\mathcal{G} \in 2^{\mathbb{F}(\mathcal{P})}$: formule d'état qui décrit les conditions nécessaires pour considérer qu'un état est terminal.

On introduit $\langle \mathbb{S}^*, \tau^* \rangle$ le LTS cible associé à $\mathcal{P}$ avec :

$$S_0 = S_{init}$$

$$\mathbb{S}^* = \{S \in 2^{\mathbb{F}(\mathcal{P})} \mid \text{il existe un ensemble d'événement applicables depuis } S_0 \text{ qui amène à } S\}$$

$$\tau^* = \{(S, \{e\}, S') \mid S \in \mathbb{S}^*, \{e\} \in 2^{\mathbb{E}(\mathcal{P})}, pre(e) \subseteq S \text{ et } S' = (S \setminus eff^-(e)) \cup eff^+(e)\}$$
$$\cup \{(S, \emptyset, S) \mid S \in \mathbb{S}^*, \mathcal{G} \subseteq S\}.$$

Et $T(\mathcal{P}) = \langle S, \tau \rangle$ avec T notre processus (parseur) et donc $T(\mathcal{P})$ le LTS obtenu en l'appliquant au problème PDDL $\mathcal{P}$.

E.1 Correction

Afin de démontrer la correction de notre parseur, nous allons montrer que le LTS construit par l'algorithme coïncide avec le LTS cible, c'est-à-dire $T(\mathcal{P}) = \langle \mathbb{S}^*, \tau^* \rangle$.

On montre dans un premier temps que $\mathbb{S} = \mathbb{S}^*$:

- $\mathbb{S} \subseteq \mathbb{S}^*$: Pour tout S appartenant $\mathbb{S}$, S a été atteint par *Breadth-First Search* (BFS) depuis S_0 en appliquant des événements dont les préconditions sont satisfaites donc il existe un chemin entre S_0 et S. On peut donc en conclure que $\mathbb{S} \subseteq \mathbb{S}^*$.
- $\mathbb{S}^* \subseteq \mathbb{S}$ Par récurrence avec l'hypothèse : Si $S^* \in \mathbb{S}^*$ et il existe $\{e\} \in 2^{\mathbb{E}(\mathcal{P})}$ tel que $pre(e) \subseteq S^*$ alors $S' \in \mathbb{S}^*$ avec $S' = (S \setminus eff^-(e)) \cup eff^+(e)$
  - — Base : $S_0 \in \mathbb{S}$, car l'algorithme BFS est initialisé avec S_0.
  - — Induction : Soit $S \in \mathbb{S}^* \cap \mathbb{S}$ et de plus, il existe $\{e\} \in 2^{\mathbb{E}(\mathcal{P})}$ tel que $pre(e) \subseteq S$. Montrons que S' définit par $S' = (S \setminus eff^-(e)) \cup eff^+(e)$ appartenant par hypothèse à $\mathbb{S}^*$ appartient aussi à $\mathbb{S}$. Lorsque le processus T traite S il teste l'ensemble des événements possibles pour tenter de les appliquer dans S. L'événement $\{e\}$ est applicable dans S donc T va construire l'état $(S \setminus eff^-(e)) \cup eff^+(e) = S'$ et va l'ajouter à $\mathbb{S}$.

  On a donc montré par induction que $\mathbb{S}^* \subseteq \mathbb{S}$.

On peut en conclure que $\mathbb{S}^* = \mathbb{S}$. Montrons maintenant que $\tau = \tau^*$.

Comme $\mathbb{S}^* = \mathbb{S}$ on peut réécrire τ^* de la façon suivante :

$$\tau^* = \{(S, \{e\}, S') \mid S \in \mathbb{S}, \{e\} \in 2^{\mathbb{E}(\mathcal{P})}, pre(e) \subseteq S \text{ et } S' = (S \setminus eff^-(e)) \cup eff^+(e)\}$$
$$\cup \{(S, \emptyset, S) \mid S \in \mathbb{S}, \mathcal{G} \subseteq S\}$$

Pour construire τ le processus T, pour tout $S, S' \in \mathbb{S}$ tel qu'il existe $\{e\} \in 2^{\mathbb{E}(\mathcal{P})}$ et $S' = (S \setminus eff^-(e)) \cup eff^+(e)$, ajoute la transition $(S, \{e\}, S')$ à τ. De plus pour tout $S \in \mathbb{S}$ tel que $\mathcal{G} \subseteq S$, T ajoute $(S, \{e\}, S)$ à τ. Formellement, on a :

$$\tau = \{(S, \{e\}, S') \mid S \in \mathbb{S}, \{e\} \in 2^{\mathbb{E}(\mathcal{P})}, pre(e) \subseteq S \text{ et } S' = (S \setminus eff^-(e)) \cup eff^+(e)\}$$
$$\cup \{(S, \emptyset, S) \mid S \in \mathbb{S}, \mathcal{G} \subseteq S\} = \tau^*$$

On a montré que $T(\mathcal{P}) = \langle \mathbb{S}^*, \tau^* \rangle$ qui est un LTS, donc notre algorithme est correct.

E.2 Terminaison

Le processus T est basé sur un algorithme BFS dont l'espace d'exploration est fini et borné par le nombre d'états possibles qui est égal à $2^{|\mathbb{F}(\mathcal{P})|}$.

E.3 Représentabilité

Nous souhaitons montrer une propriété de représentabilité sur le sous-ensemble de LTS obtenables avec notre parseur (pas de nœud isolé, un événement unique par transition et au moins une transition réflexive). C'est-à-dire, montrer que tout LTS obtenu par notre parseur peut être exprimé sous forme d'un problème PDDL. Cette propriété s'apparente à une forme de complétude plus souple : une complétude au sens strict exigerait une forme de correspondance dans les deux sens entre les deux formalismes. C'est-à-dire qu'un LTS obtenu avec notre parseur puisse être exprimé en PDDL, mais également que ce problème PDDL, une fois retraduit par notre parseur, redonne exactement le LTS de départ.

Donnée Soit un LTS défini par $\langle \mathbb{S}, \tau \rangle$, tel que $\mathbb{S} \subseteq 2^{\mathbb{F}}$ et $\tau \subseteq \mathbb{S} \times 2^{\mathbb{E}} \times \mathbb{S}$, $S_0 \in \mathbb{S}$. Nous allons montrer qu'il est possible de construire un domaine et un problème PDDL $\mathbb{P}$ tel que $T(\mathcal{P}) = \langle \mathbb{S}, \tau \rangle$.

Construction du problème PDDL associé On construit $\mathcal{P} = (\mathcal{O}, \mathcal{A}, Pred, S_{init}, \mathcal{G})$ de la façon suivante :

- $\mathcal{O} = \{o\}$ on définit un unique objet pour tous les problèmes associés (nb : on pourrait ne pas en mettre du tout, mais les prédicats ne porteraient plus sur rien et notre parseur ne gère pas les actions sans paramètres).
- $Pred = \{f(o) \mid \forall f \in \mathbb{F}\}$: l'ensemble des prédicats ont une arité d'un. L'unique objet/paramètre ne représente rien, mais sert de "levier" pour dire si un prédicat est vrai ou faux.
- Pour chaque transition $(S, E, S') \in \tau$ on construit l'action associée $a \in \mathcal{A}$ de la façon suivante :
  - $param(a) = o$
  - $pre(a) = \{f(o) \mid \forall f \in S\} \cup \{notf(o) \mid \forall f \notin S\}$. On explicite la négation des fluents absents de l'état de départ pour que chaque action soit uniquement applicable entre les deux états de la transition et nulle part ailleurs.
  - $eff^+(a) = \neg S \cap S'$ avec $\neg S = \{\neg s \mid s \in S\}$
  - $eff^-(a) = S \cap \neg S'$ avec $\neg S' = \{\neg s \mid s \in S'\}$
- $S_{init} = \{f(o) \mid f \in S_0\}$

- $\mathcal{G}$ est construite à partir de $\mathbb{A} = \{S \mid S \in \mathbb{S}, (S, \varnothing, S) \in \tau\}$. La formule $\mathcal{G}$ correspond à la réunion des états appartenant à $\mathbb{A}$.

Nous avons démontré une propriété de représentabilité : il existe pour l'ensemble des LTS qui peuvent être obtenus par notre parseur une possibilité de les reconvertir en problème PDDL, sans perte d'information sémantique. Cependant, il est à noter que sur le plan computationnel la correspondance est inapplicable avec un solveur PDDL. En effet, nous restreignons l'application d'une action à une unique état en générant des préconditions de taille $\mid \mathcal{F} \mid$ ce qui fait exploser la combinatoire du problème et perdre l'intérêt du solveur.

Cette transition inverse est peu optimale. Une autre possibilité de démonstration intéressante serait de construire un PDDL moins restreint et plus compact. En contrepartie des états non présents dans le LTS de base pourrait être atteints en appliquant notre parseur au PDDL construit. Dans tous les cas, pour notre parseur actuel, il n'existe pas d'application inverse qui reconstruise à l'identique le problème PDDL qui a permis d'obtenir un LTS.

F PDDL

F.1 Domaine Block World classique

```
(define (domain bw)
  (:requirements :strips)
  (:constants red green blue)
  (:predicates
      (on ?x ?y)       ; object ?x is on ?object ?y
      (on-table ?x)    ; ?x is directly on the table
      (clear ?x)       ; ?x has nothing on it
      (arm-empty)      ; robot isn't holding anything
      (holding ?x))    ; robot is holding ?x

  ;; les quatres actions classique de manipulation d'objet
  (:action pick-up
     :parameters (?ob1)
     :precondition (and (clear ?ob1) (on-table ?ob1) (arm-empty))
     :effect
     (and (not (on-table ?ob1))
             (not (clear ?ob1))
             (not (arm-empty))
             (holding ?ob1)))

  (:action put-down
     :parameters (?ob)
     :precondition (holding ?ob)
     :effect
     (and (not (holding ?ob))
           (clear ?ob)
           (arm-empty)
           (on-table ?ob)))

  (:action stack
     :parameters (?sob ?sunderob)
     :precondition (and (holding ?sob) (clear ?sunderob))
     :effect
     (and (not (holding ?sob))
           (not (clear ?sunderob))
           (clear ?sob)
           (arm-empty)
           (on ?sob ?sunderob)))

  (:action unstack
     :parameters (?sob ?sunderob)
     :precondition (and (on ?sob ?sunderob) (clear ?sob) (arm-empty))
```

```
    :effect
    (and (holding ?sob)
         (clear ?sunderob)
         (not (clear ?sob))
         (not (arm-empty))
         (not (on ?sob ?sunderob))))
)
```

F.2 Domaine et problème du Poison

Les fichiers PDDL permettant d'obtenir le LTS de la section 6 sont les suivants :

```
(define (domain poison)

  (:requirements :strips :negative-preconditions :disjunctive-preconditions)

  (:predicates
    (ok ?v)
    (emp ?v)
    (anti ?v)
    (vide ?v)
    (mort ?v)
    (vivant ?v)
  )
  (:action boire_vo
    :parameters (?v)
    :precondition    (and (ok ?v) (not (emp ?v))
                      (not (anti ?v)) (not (vide ?v))
                      (not (mort ?v)) (not (vivant ?v)))
    :effect (and (not (ok ?v))
                 (vivant ?v))
  )

  (:action emp
    :parameters (?v)
    :precondition   (and (ok ?v) (not (emp ?v))
                         (not (anti ?v)) (not (vide ?v))
                         (not (mort ?v)) (not (vivant ?v)))
    :effect (and
              (not (ok ?v))
              (emp ?v))
  )

  (:action vider_vo
    :parameters (?v)
    :precondition   (and (ok ?v) (not (emp ?v))
                         (not (anti ?v)) (not (vide ?v))
                         (not (mort ?v)) (not (vivant ?v)))
    :effect (and
              (not (ok ?v))
              (vide ?v))
  )

  (:action anti
    :parameters (?v)
    :precondition   (and (not (ok ?v)) (emp ?v)
                         (not (anti ?v)) (not (vide ?v))
                         (not (mort ?v)) (not (vivant ?v)))

    :effect (and
              (not (emp ?v))
              (anti ?v))
  )
```

```
  (:action boire_ve
    :parameters (?v)
    :precondition   (and (not (ok ?v)) (emp ?v)
                         (not (anti ?v)) (not (vide ?v))
                         (not (mort ?v)) (not (vivant ?v)))

    :effect (and (not(emp ?v)) (mort ?v))
  )

  (:action vider_ve
    :parameters (?v)
    :precondition   (and (not (ok ?v)) (emp ?v)
                         (not (anti ?v)) (not (vide ?v))
                         (not (mort ?v)) (not (vivant ?v)))
    :effect (and (not (emp ?v)) (vide ?v))
  )

  (:action rien
    :parameters (?v)
    :precondition   (and (not (ok ?v)) (not (emp ?v))
                         (not (anti ?v)) (vide ?v)
                         (not (mort ?v)) (not (vivant ?v)))

    :effect (and (not (vide ?v)) (mort ?v))
  )

  (:action boire_va
    :parameters (?v)
    :precondition   (and (not (ok ?v)) (not (emp ?v))
                         (anti ?v) (not (vide ?v))
                         (not (mort ?v)) (not (vivant ?v)))

    :effect (and (not (anti ?v)) (vivant ?v))
  )

)


(define (problem poison_p0)
    (:domain poison)
    (:objects V)

    (:init (ok V))

    (:goal (or (vivant V) (mort V))))
```

Références

Leila Amgoud et Martin Cooper (2026). *Axiomatic Foundations of Counterfactual Explanations*. arXiv : 2602.04028 [cs.AI].

Lars Buesing et al. (2018). « Woulda, Coulda, Shoulda : Counterfactually-Guided Policy Search ». In : *CoRR* abs/1811.06272. arXiv : 1811.06272.

Marina A. D'Amico (2026). « An Interventionist Approach to Causal Selection : The Optimal Control Hypothesis ». In : *Journal of Philosophy*.

Shuyang Dong, Shangtong Zhang et Lu Feng (2025). *Counterfactual Explanations for Continuous Action Reinforcement Learning*. arXiv :2505.12701 [cs]. doi : 10.48550/arXiv.2505.12701.

Jasmina Gajcin et Ivana Dusparic (2024). « Redefining counterfactual explanations for reinforcement learning : Overview, challenges and opportunities ». In : *ACM Computing Surveys* 56.9, p. 1-33.

Riccardo Guidotti (2024). « Counterfactual explanations and how to find them : literature review and benchmarking : R. guidotti ». In : *Data mining and knowledge discovery* 38.5, p. 2770-2824.

Joseph Y Halpern (2016). *Actual causality*. MiT Press.

Herbert LA Hart (1978). « Honoré (1959). Causation in the Law ». In : *NY : Oxford*.

Paul Henne et al. (2021). « Counterfactual thinking and recency effects in causal judgment ». In : *Cognition* 212, p. 104708. issn : 0010-0277. doi : 10.1016/j.cognition.2021.104708.

Hume (1748). *Philosophical Essays Concerning Human Understanding — Wikisource*.

Thomas F. Icard, Jonathan F. Kominsky et Joshua Knobe (2017). « Normality and actual causal strength ». In : *Cognition*. doi : 10.1016/j.cognition.2017.01.010.

Jonathan F. Kominsky et al. (2015). « Causal superseding ». In : *Cognition* 137, p. 196-209. issn : 0010-0277. doi : 10.1016/j.cognition.2015.01.013.

Konstantin Raphael Kueffner (2021). « A comprehensive Survey of the actual causality literature ». Accepted : 2021-11-23T10 :19 :29Z. Thesis. Technische Universität Wien. doi : 10.34726/hss.2021.90003.

Jessica Lally, Milad Kazemi et Nicola Paoletti (2026). *Robust Counterfactual Inference in Markov Decision Processes*. arXiv : 2502.13731 [cs.AI].

David Lewis (1973). « Causation ». In : *The journal of philosophy* 70.17, p. 556-567.

Ann L. McGill et Ann E. Tenbrunsel (2000). « Mutability and propensity in causal selection. » In : *Journal of Personality and Social Psychology*. doi : 10.1037/0022-3514.79.5.677.

Peter Menzies et Helen Beebee (2025). « Counterfactual Theories of Causation ». In : *The Stanford Encyclopedia of Philosophy*. Sous la dir. d'Edward N. Zalta et Uri Nodelman. Winter 2025. Metaphysics Research Lab, Stanford University.

Judea Pearl (2009). *Causality*. Cambridge University Press.

Kevin Reuter et al. (2014). « The good, the bad, and the timely : how temporal order and moral judgment influence causal selection ». English. In : *Frontiers in Psychology* 5. issn : 1664-1078. doi : 10.3389/fpsyg.2014.01336.

F Dupin de Saint-Cyr et al. (2014). « Raisonnement sur l'action et le changement ». In : *Panorama de l'intelligence artificielle. Ses bases méthodologiques, ses développements* 1, p. 255-282.

Camilo Sarmiento (2025). « Formalising Overdetermination in a Labelled Transition System ». en. In.

Camilo Sarmiento et al. (2023). *Action Languages Based Actual Causality for Computational Ethics : a Sound and Complete Implementation in ASP*. arXiv : 2205.02919 [cs.AI].

Camilo Sarmiento Lozano (2024). « Formalisation des raisonnements éthiques : modélisation des processus en éthique et modélisation, représentation et automatisation du raisonnement causal ». Theses. Sorbonne Université. doi : 10.70675/83f2462fz402cz4a87z8d56zccdfd880ef17.

Sahil Verma et al. (2022). *Counterfactual Explanations and Algorithmic Recourses for Machine Learning : A Review*. arXiv : 2010.10596 [cs.LG].

Sandra Wachter, Brent D. Mittelstadt et Chris Russell (2017). « Counterfactual Explanations without Opening the Black Box : Automated Decisions and the GDPR ». In : *CoRR* abs/1711.00399. arXiv : 1711.00399.

Richard W Wright (1985). « Causation in tort law ». In : *California Law Review* 73, p. 1735.